Universidade Federal de Sergipe

Centro de Ciências Exatas e Tecnologia

Departamento de Física

Curso de Física: Habilitação em Astrofísica

Camille Vitória de Jesus Porto

Cálculo do Espectro da Radiação Cósmica de Fundo com Regressão Simbólica

Trabalho de Conclusão de Curso

São Cristóvão - SE
Brasil
2025

Camille Vitória de Jesus Porto

Cálculo do Espectro da Radiação Cósmica de Fundo com Regressão Simbólica

Trabalho de Conclusão de Curso apresentado ao Departamento de Física da Universidade Federal de Sergipe, como requisito parcial para a obtenção do título de Bacharela em Física: Habilitação em Astrofísica

Orientador: Prof. Dr. Luciano Casarini

São Cristóvão - SE
2025

Dedico este trabalho à minha
constelação de estrelas-guia:
Minha mãe e meus avós.

Agradecimentos

Agradeço primariamente a Deus, pela força e capacidade para seguir nesta longa caminhada. Agradeço à minha mãe, Joelma, por ouvir, acreditar e participar dos meus sonhos, por mais longe do chão que estivessem. Aos meus avós, Maria do Carmo e Heribaldo, Luzia e Joel, que estiveram presentes a cada nova etapa. Às minhas tias, Lucimara e Crislane, e aos meus primos, tios, pai e padrasto, por toda compreensão e acolhida. Sem vocês, eu nada seria.

Agradeço aos amigos que a vida me deu o prazer de conhecer e estiveram presentes em momentos diversos dessa jornada, em especial, Kauan, Mari, Fillipe, Daniel, Helen, Ana Claudia. Vocês me inspiram a ser melhor a cada dia. Agradeço também às pessoas que pude conhecer em razão desta escolha universitária: Bia, Alisson, Rafael, David, Matheus, Laize, Quito, Bruno, Gabriel, Lara, Adriel, Alycia, Sabrina, Alê, Letícia, Pedro, Cameron, Thulio, Emmanuel e tantos outros com os quais pude dividir os momentos alegres, extravasar nos momentos caóticos, chorar nos momentos tristes. A verdadeira beleza da trajetória está nos amigos que podemos fazer pelo caminho.

Agradeço imensamente aos orientadores que tive ao longo dos anos: Adeline, sem a qual não teria a coragem necessária para fazer ciência sem deixar de acreditar no potencial transformador da gentileza e da compaixão; Sergio, com o qual pude aprender não só sobre o trabalho de astrofísico e professor universitário, mas também a não esquecer que somos seres humanos; Fábio, com o qual pude me reconectar à primeira das minhas paixões: a matemática; Lara Arguelho, cuja parceria permitiu expandir os horizontes de ação em outra paixão: a educação; Luciano, que pelo crédito genuíno nas minhas capacidades, me fez mais capaz. Feliz é o estudante que pode contar com bons orientadores, e eu pude contar com os melhores para que a minha formação fosse primorosa, sem deixar de ser humana.

Agradeço ao CNPq e à CAPES, órgãos de fomento que possibilitaram o desenvolvimento do meu trabalho em diversas frentes ao longo dos anos, através de bolsas de pesquisa e extensão, por meio dos projetos associados à OBMEP (PIC Jr. e PICME), à pesquisa durante o IFS e à Caravana Luar do Sertão.

Por fim, agradeço a pessoas não mencionadas antes (e às que precisam ser menciona-

das novamente) e intrinsecamente relacionadas aos feitos que me são especiais durante minha trajetória na UFS.

Às pessoas que pude conhecer e conviver no âmbito da Caravana Luar do Sertão, projeto que me rendeu não só uma amplitude de conhecimentos, mas também o propósito necessário para persistir durante a formação em astrofísica. Deixo aqui gravado o nome de parte destas pessoas: Matheus, Mariana, Thainá, Magna, David, Joel, Mislene, Adriel, Alycia, Emerson, Lara, Bia, Maris e Anailson. Agradeço principalmente ao professor Sergio, sem o qual este projeto e todas as benesses provenientes dele não seriam possíveis.

Agradeço ao meu grande amigo Kauan, com o qual tive a coragem de transformar a vontade de mudar o mundo e retribuir os privilégios de estudar em uma instituição amplamente voltada ao pensamento crítico e científico em um projeto que floresce a cada dia, o Ciência é Fundamental. Agradeço também às pessoas que contribuíram para que o CéF se tornasse o que é hoje: Helen, Adeline, Yzila, Rebeca, Lara Arguelho, Jê, Lara, Theed, Lucas Satoshi, Lucas Oliveira, Fabi, Ellen, Brenddáh e Ivan.

Agradeço novamente à minha família, por compreender e empreender sacrifícios para que este momento chegasse – e por todas as eventuais preocupações; ao professor Sergio, por todo o cuidado e apoio e por ter concedido a infraestrutura computacional para que os resultados aqui apresentados fossem possíveis; ao David, pelo companheirismo e escuta, mesmo quando as palavras já nem me faziam sentido; ao Matheus, por ser exemplo, sobretudo, de serenidade; ao Rafael, por ser a voz da confiança que por vezes me faltou; a Alisson, Kauan, Mari, Fillipe e Daniel, que mesmo quando não presentes no dia a dia, acompanharam meus planos insanos e torceram pela minha felicidade e sucesso por meio de mensagens no meio dos dias, noites e madrugadas; a todos no SOAR, por toda ajuda, incentivo e risadas; ao Pedro, pelas contribuições que aprimoraram e por vezes permitiram o andamento deste trabalho; e ao professor Luciano, por me apresentar a Cosmologia enquanto área de pesquisa, pela justa orientação, pela sinceridade e conselhos oferecidos e por toda sua compreensão e solicitude durante o processo.

"*Seja corajoso, seja curioso, seja determinado, supere as probabilidades. É possível.*"

(***Stephen Hawking***)

Resumo

Este trabalho busca a obtenção de uma equação descritiva da forma do espectro de potências em função dos parâmetros cosmológicos, utilizando um algoritmo de regressão simbólica. Foram avaliados 100 espectros obtidos a partir da variação de parâmetros cosmológicos dentro de $\pm 5\sigma$ dos valores obtidos pelo Planck. Foram efetuados diferentes métodos de tratamento dos dados de saída durante a etapa de validação, sendo selecionado o método de normalização, que apresentou os menores valores de MSE. Durante o teste, o modelo foi avaliado para dados correspondentes a variações dos parâmetros dentro dos intervalos de $\pm 1\sigma$ e $\pm 2\sigma$. O R^2 para esses intervalos foi de $0,99881$ e $0,99863$, respectivamente. Os desvios mínimos e máximos ficaram abaixo de 10% para $\ell < 1500$, aumentando para multipolos maiores, nos quais os desvios variaram em torno de 25% para $1500 \leq \ell \leq 2200$ e atingiram 80% para $\ell > 2200$. Estes resultados apontam para a necessidade de refinamento do modelo descrito, modificando este método ou combinando-o com outros métodos de aprendizagem.

Palavras Chaves: Radiação Cósmica de Fundo, Espectro de Potências da CMB, Regressão Simbólica.

Abstract

This work aims to derive, with a symbolic regression algorithm, an equation that describes the shape of the CMB power spectrum as a function of cosmological parameters. To this end, datasets of 100 spectra were generated using cosmological parameters sampled within a $\pm 5\sigma$ range from the values reported by Planck collaboration. Different methods for processing the output data were evaluated for selection of the best method in validation phase, resulting in the choice of the data normalization method. This method yielded the lowest mean squared error (MSE). For the test phase, the model was evaluated data within $\pm 1\sigma$ and $\pm 2\sigma$ intervals of parameter variations. The coefficient of determination (R^2) for these intervals were 0.99881 and 0.99863, respectively. The minimum and maximum deviations remained below 10% for $\ell < 1500$, with deviations around 25% in the range $1500 \leq \ell \leq 2200$ and reaching up to 80% for $\ell > 2200$. These results indicate the need for further refinement of the proposed model, either by improving the current method or by combining it with other learning techniques.

Keywords: Cosmic Microwave Radiation, CMB Power Spectrum, Symbolic Regression

Sumário

1 Introdução **1**

2 Revisão de Literatura **3**

2.1 Cosmologia 3

2.1.1 O Espaço sob a Métrica de Robertson-Walker 3

2.1.2 Dinâmica de um Universo em Expansão 8

2.1.3 Recombinação e Desacoplamento 16

2.1.4 A Radiação Cósmica de Fundo 22

2.1.5 Espectro de Potências da Matéria 25

2.1.6 Espectro de Potências das Flutuações Iniciais de Curvatura 26

2.1.7 Influência dos Parâmetros Cosmológicos no Espectro de Potência . . . 27

2.2 Códigos de Boltzmann 29

2.3 Aprendizado de Máquina 31

2.3.1 Tipos de Aprendizado 31

2.3.2 Regressão Simbólica 32

2.3.3 Underfitting e Overfitting 33

3 Metodologia **35**

3.1 Definição do Método e Preparação dos Dados 35

3.1.1 Escolha das *Features* 35

3.1.2 Variação dos Parâmetros de Entrada 36

3.1.3 Obtenção dos Dados de Saída 36

3.1.4 Tratamento dos Dados 38

3.2 Execução da Regressão Simbólica 41

3.2.1 PySR 41

3.2.2 Escolha da Equação Final 43

3.3 Métricas de Performance 44

3.3.1 R^2 44

3.3.2 Erro Relativo 45

4 Resultados e Discussão **46**
4.1 Validação e Escolha da Equação Final 46
4.2 Avaliação de Performance 48

5 Conclusões **53**

Referências **55**

APÊNDICES **60**

Apêndice A Configurações Utilizadas no CLASS **61**

Apêndice B Configurações Utilizadas na Regressão Simbólica **63**

Lista de Figuras

2.1 Evolução do fator de escala, coordenadas físicas e coordenadas comóveis ao longo do tempo. Retirado de Baumann (2022) [1]. 5

2.2 Evolução das densidades de radiação, matéria e constante cosmológica. 14

2.3 Medidas da intensidade média em função da frequência e curva de corpo negro fixada *a priori*. Retirado de Fixsen, 2009. [2] 23

2.4 Mapa de distribuições das galáxias em função do redshift e da Ascensão Reta obtido pelo *2dF Galaxy Redshift Survey*. Retirado de Colless *et al.*, 2003 [3]. . 26

2.5 Influência dos parâmetros $\Omega_m h^2$ e Ω_m na forma do espectro de potências da CMB. Os gráficos da linha inferior apresentam o valor relativo dos espectros em relação aos valores do espectro traçado a partir dos parâmetros obtidos pela colaboração Planck (2020a) [4]. 28

2.6 Influência dos parâmetros $\Omega_b h^2$ e $10^9 A_s$ na forma do espectro de potências da CMB. Os gráficos da linha inferior apresentam o valor relativo dos espectros em relação aos valores do espectro traçado a partir dos parâmetros obtidos pela colaboração Planck (2020a) [4]. 29

2.7 Influência dos parâmetros n_s e τ_{reio} na forma do espectro de potências da CMB. Os gráficos da linha inferior apresentam o valor relativo dos espectros em relação aos valores do espectro traçado a partir dos parâmetros obtidos pela colaboração Planck (2020a) [4]. 30

2.8 *Expression tree* representativa da função $(\log(x))^{\theta_0} + \exp(\theta_1 x)$. Retirado de Bartlett *et al.*, 2023 [5]. 33

3.1 Distribuição do conjunto de parâmetros para 100 amostras com a variação aleatória dos valores dentro do intervalo de $\pm 5\sigma$ obtidos pela colaboração Planck (2020a) [4]. 37

3.2 Distribuição do conjunto de parâmetros dos dados de treino. 37

3.3 Distribuição dos valores dos parâmetros $\Omega_m h^2$, Ω_m, $\Omega_b h^2$, $10^9 A_s$, n_s e τ_{reio} para 10 dos espectros utilizados durante o treino. Nestes gráficos, a fim de permitir a melhor visualização e comparação com os gráficos da parte inferior das figuras 2.5 a 2.7, os valores dos D_ℓ^{TT} de cada espectro foram divididos pelo valor computado a partir dos valores obtidos pela colaboração Planck (2020a) [4]. 39

3.4 Esquematização do processo de *loop* externo do PySR. Retirado de Cranmer (2023) [6]. 42

4.1 MSE das etapas de treino e validação em função da complexidade das equações fornecidas ao fim da regressão simbólica. 47

4.2 *Loss* (MSE) e *Score* das equações obtidas a partir do treino em função da complexidade. A linha horizontal contínua no primeiro gráfico apresenta o valor máximo de *loss* considerado de acordo com o método de seleção *best*. A linha vertical contínua em ambos os gráficos apresenta a complexidade correspondente a esse valor, ou seja, ela representa a complexidade a partir da qual foram avaliados os *scores* para a seleção da equação. A linha pontilhada representa a equação escolhida – a com maior *score* dentre as consideradas – para as análises detalhadas a seguir. 48

4.3 Funções P_1, P_2 e $1/P_3$ plotadas para o modelo cosmológico padrão. 49

4.4 Comparação entre os D_b obtidos a partir dos dados computados pelo CLASS e os $\hat{D}_b$ preditos por meio da equação 4.1, obtida a partir da regressão simbólica para variações de parâmetros dentro do intervalo de $\pm 5\sigma$. No gráfico superior, além da distribuição desses valores, apresentam-se as medidas de R^2 para variações dos parâmetros dentro dos intervalos de $\pm 1\sigma$ e $\pm 2\sigma$. No gráfico inferior, encontra-se a razão entre o valor predito e o valor computado pelo CLASS para cada dado utilizado no teste. 50

4.5 Desvios máximos e mínimos dos valores de $\hat{D}_b$ para variações de parâmetros dentro dos intervalos de $\pm 1\sigma$ e $\pm 2\sigma$. 51

4.6 Espectros de potência obtidos para os parâmetros estimados pela colaboração Planck (2020a) [4] computados com o uso do CLASS (em laranja) e do modelo treinado com regressão simbólica (em azul). Na parte inferior da figura é apresentada a razão entre os valores preditos e os valores computados pelo CLASS. 52

Lista de Tabelas

3.1 Valores e incertezas encontrados pela colaboração Planck (2020a) [4] para os parâmetros cosmológicos selecionados. 36
3.2 Larguras de *bin* usadas dentro de cada intervalo de ℓs. Os valores apresentados foram obtidos no artigo V da colaboração Planck (2020b) [7]. 38
3.3 Valores máximo e mínimo dos D_b dos espectros obtidos para os dados do treino em que foi feita apenas a normalização. 40
3.4 Média e desvio-Padrão dos D_b dos espectros obtidos para os dados do treino em que foi feita apenas a standardização. 41
3.5 Valores máximos e mínimos dos D_b dos espectros obtidos para os dados do treino em que foi feita a aplicação de escala logarítmica seguida por normalização. 41
3.6 Média e desvio-Padrão dos D_b dos espectros obtidos para os dados do treino em que foi aplicada a escala logarítmica seguida pela standardização. 41

4.1 Resultados durante a etapa de validação para os diferentes conjuntos de tratamentos dos dados de saída. 46
4.2 Valores das constantes listadas nas equações 4.1 a 4.4. 49

A.1 Parâmetros fixos usado para a computação dos C_ℓ^{TT} usados. 61
A.2 Parâmetros do CLASS variados para obtenção dos espectros e valores mínimos e máximos dentro dos quais os parâmetros poderiam variar. 62

B.1 Configurações fornecidas durante o treino dos dados. 63

Capítulo

1

Introdução

A Radiação Cósmica de Fundo, também usualmente referida como Fundo Cósmico em Microondas – ou ainda pela sigla CMB, do termo em inglês *Cosmic Microwave Background* –, foi detectada pela primeira vez por Arno Penzias e Robert Wilson em 1965, sob a forma de um excesso de temperatura em suas medições de aproximadamente 3,5 K. Dentro dos limites de suas observações, este "excesso" era isotrópico, não polarizado e livre de variações temporais (Penzias e Wilson, 1965 [8]), algo condizente com as predições de uma temperatura de fundo resultante da expansão do Universo feitas por Alpher e Herman (1949) [9] durante seu desenvolvimento do modelo do Big Bang.

Sua origem advém dos primeiros momentos após a inflação, nos quais o Universo ainda era bastante denso e quente, condição que não favorecia a combinação de prótons e elétrons para a formação de hidrogênio neutro, pois, como a grande maioria dos fótons tinha energia suficiente para ionizar os átomos de hidrogênio, estas partículas mantinham-se separadas. O maior número de partículas não ligadas favorecia a interação de fótons e elétrons através do espalhamento Thomsom, mantendo estes fótons acoplados à matéria bariônica. No momento em que as interações por espalhamento Thomsom deixam de ser frequentes, definido como o momento em que a taxa dessas interações iguala-se à taxa de expansão do Universo, esses fótons encontram-se livres para deslocar-se e eventualmente serem detectados.

Além de ser a mais antiga radiação luminosa à qual se tem acesso, a CMB também é uma importante ferramenta para o entendimento do Universo antes e após o desacoplamento. Com o lançamento do satélite COBE (*Cosmic Background Explorer*), foi possível verificar não só que a distribuição de temperaturas da CMB segue uma distribuição de corpo negro (Fixsen *et al.*, 1996 [10]), mas também a presença de flutuações de temperatura na CMB (Smoot *et al.*, 1992 [11]), chamadas de anisotropias.

No ano 2000, o experimento BOOMERanG (*Ballon Observations Of Millimetric Extragalactic Radiation ANd Geophysics*) [12] forneceu medidas das anisotropias da CMB em uma escala angular de aproximadamente 1°. Satélites de gerações posteriores, como o WMAP (*Wilkinson Microwave Anisotropy Probe*) [2] e o Planck [13] seguiram permitindo conhecer melhor as características da CMB e melhorando a precisão das medidas. A partir do estudo estatístico das anisotropias, tornou-se possível a determinação de parâmetros cosmológicos através do estudo estatístico dessas anisotropias.

Essa extração de parâmetros é feita a partir do uso de códigos de Boltzmann, que são algoritmos que simulam a evolução das pertubações iniciais no Universo, possibilitando a comparação entre a teoria cosmológica e os dados observacionais através dos espectros de potência das anisotropia da Radiação Cósmica de Fundo. Seu uso para tal fim é feito dentro dos códigos de Monte Carlo, que os executam milhares vezes para possibilitar a exploração do espaço de parâmetros e a obtenção de regiões de confiança para os valores desses parâmetros. Como o tempo computacional é dominado pelos códigos de Boltzmann, a criação de ferramentas que permitam a obtenção destes espectros a partir de um determinado conjunto de parâmetros em um tempo reduzido, é alvo de interesse para a cosmologia moderna.

Uma forma de diminuir o tempo gasto para a obtenção destes espectros é através do uso de algoritmos de aprendizado de máquina, que são ferramentas capazes de aprender e extrair informações a partir dos dados. A regressão simbólica é um tipo de aprendizado de máquina que baseia-se na descrição do conjunto de dados a partir de expressões matemáticas, o que torna-a um tipo de aprendizado de potencial interesse para uso no descobrimento de leis físicas.

Diante disso, este trabalho busca a obtenção de uma equação que descreva a forma do espectro de potências da Radiação Cósmica de Fundo a partir dos parâmetros cosmológicos, com o uso da regressão simbólica.

Os conceitos-chave em Cosmologia, códigos de Boltzmann e Aprendizado de Máquina, temas que fundamentam este trabalho, são abordados no capítulo 2; no capítulo 3 é definida a metodologia utilizada; o capítulo 4 traz a discussão acerca dos principais resultados obtidos. Por fim, no capítulo 5 são feitas as conclusões e delineadas as perspectivas acerca desses resultados.

Capítulo

2

Revisão de Literatura

2.1 Cosmologia

Os primeiros indícios observacionais de que o Universo estaria se expandindo surgiram a partir do estudo das até então chamadas nebulosas espirais – hoje conhecidas como galáxias. Através da análise espectroscópica da luz proveniente desses objetos, trabalhos como o de Slipher (1915) [14], o de Lundmark (1924) [15] e o de Hubble (1929) [16] foram capazes de perceber que suas velocidades relativas correspondiam a um desvio da luz para comprimentos de onda mais avermelhados.

Embora inicialmente esse desvio fosse atribuído ao deslocamento da fonte, com o tempo verificou-se que esses deslocamentos eram mais condizentes com uma origem cosmológica, conforme proposto por Lemaître em 1927 [17]. Em seu artigo, Lemaître previu teoricamente a relação observada por Hubble, além de atribuí-la a um universo homogêneo e isotrópico [i] em expansão, a partir da derivação das equações da relatividade geral propostas por Einstein.

Antes de Lemaître, Alexander Friedmann (1922/1999, 1924/1999) [19, 20] já havia formulado soluções dinâmicas das equações de Einstein para universos homogêneos e isotrópicos com diferentes curvaturas, encontrando as conhecidas equações de Friedmann, a serem discutidas na seção 2.1.2. Além disso, Robertson (1935) [21] e Walker (1937) [22] elaboraram independentemente a métrica do espaço para o qual estas equações são válidas, a ser discutida na seção 2.1.1. Juntos, esses autores constituem os principais nomes para o modelo de Friedmann–Lemaître–Robertson–Walker (FLRW), base da cosmologia moderna.

2.1.1 O Espaço sob a Métrica de Robertson-Walker

O princípio cosmológico estabelece que as leis da física, e consequentemente todas as observações de fenômenos físicos, invariam frente a transformações para observadores em pontos distintos do Universo.

[i] Cabe ressaltar que a homogeneidade e isotropia, propriedades de invariância do Universo frente a translações e rotações respectivamente, só são válidas em largas escalas, isto é, acima de 100 Mpc, conforme sugerido por estudos de surveys de galáxias, como o feito por Labini e Baryshev em 2010 [18].

Em um universo homogêneo e isotrópico, para o qual é válido o princípio cosmológico, e que está evoluindo no tempo – se expandindo –, a métrica será[ii]

$$ds^2 = g_{\mu\nu}dx^\mu dx^\nu = -c^2dt^2 + dl^2 = -c^2dt^2 + a^2(t)g_{ij}dx^i dx^j \tag{2.1}$$

onde $a(t)$ é o fator de escala, uma medida adimensional das coordenadas espaciais ao longo do tempo e $d\sigma^2 = g_{ij}dx^i dx^j$ é a métrica de um espaço de curvatura constante que atende às condições de homogeneidade e isotropia. É possível escrever g_{ij} por meio de coordenadas comóveis[iii] esféricas (x, θ, ϕ) tais que:

$$g_{ij} = \begin{pmatrix} \dfrac{1}{1-Kx^2} & 0 & 0 \\ 0 & x^2 & 0 \\ 0 & 0 & x^2\sin^2\theta \end{pmatrix}, \tag{2.2}$$

em que K é a curvatura do espaço e equivale a $K = k/R_0^2$, sendo R_0 o raio de curvatura desse espaço e k o parâmetro de curvatura, uma constante que indica a geometria do espaço e pode assumir os valores $\{-1, 0, +1\}$, correspondendo a espaços do tipo hiperbólico, euclidiano e esférico, respectivamente.

Substituindo a equação 2.2 na equação 2.1, tem-se:

$$ds^2 = -c^2dt^2 + a^2(t)\left(\frac{1}{1-Kx^2}dx^2 + x^2d\theta^2 + x^2\sin^2\theta d\phi^2\right), \tag{2.3}$$

ou, escrevendo ds^2 em termos de uma coordenada radial comóvel generalizada r, de forma que $dr^2 = \dfrac{1}{1-Kx^2}dx^2$:

$$ds^2 = -c^2dt^2 + a^2(t)\left[dr^2 + S_k^2(r)\left(d\theta^2 + \sin^2\theta d\phi^2\right)\right], \tag{2.4}$$

onde

$$x \equiv S_k(r) = \begin{cases} R_0\sin(r/R_0) \\ r \\ R_0\sinh(r/R_0) \end{cases} \quad \text{para } k = \begin{cases} +1 \\ 0 \\ -1 \end{cases} \tag{2.5}$$

Fator de Escala

O fator de escala adimensional $a(t)$ é uma medida de como as coordenadas físicas se expandem ou se contraem em um universo homogêneo e isotrópico ao longo do tempo (Ryden, 2017 [23]). Ele é parametrizado de tal forma que, no tempo presente, $a(t = t_0) \equiv 1$.

[ii] Neste caso, foi usada a assinatura $(-,+,+,+)$.

[iii] Coordenadas comóveis são coordenadas que não variam com a expansão do espaço, estando relacionadas às coordenadas físicas por meio do fator de escala.

O fator de escala estabelece uma relação de proporcionalidade entre as distâncias em coordenadas físicas, que correspondem à medida real do Universo, e as distâncias em coordenadas comóveis, um sistema de coordenadas estabelecido de maneira que a posição de um observador em repouso nele não varie, conforme pode ser visto na figura 2.1. Tal relação pode ser descrita por meio dos elementos de distância, onde

$$dl = a(t)d\sigma. \tag{2.6}$$

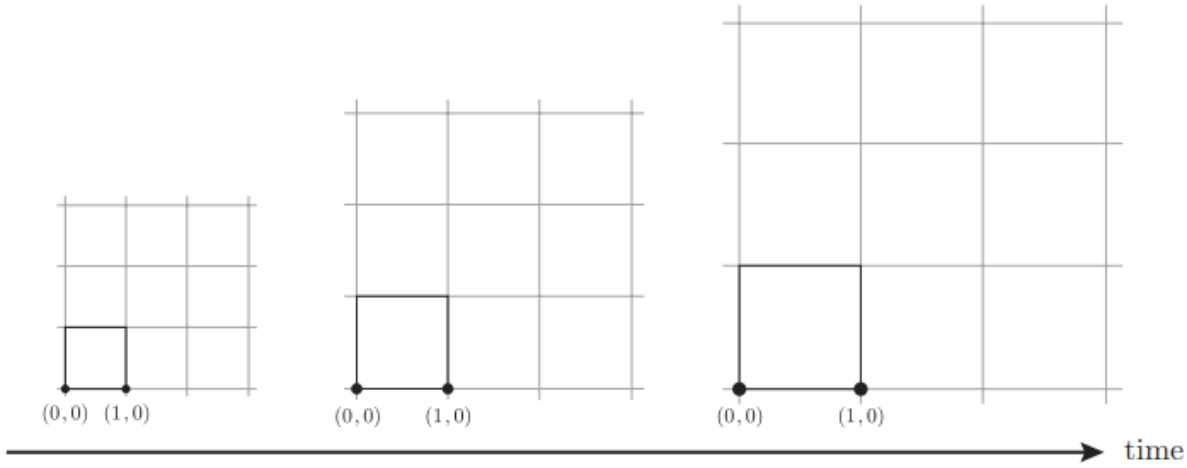

Figura 2.1: Evolução do fator de escala, coordenadas físicas e coordenadas comóveis ao longo do tempo. Retirado de Baumann (2022) [1].

Distância Própria

A distância própria corresponde à distância física entre dois objetos no espaço a um tempo fixo e, portanto, pode ser obtida a partir da métrica espacial:

$$d_p(t) = \int_C dl = a(t) \int_C d\sigma. \tag{2.7}$$

Devido ao princípio cosmológico, não há direções ou posições preferenciais no Universo, portanto o sistema de coordenadas comóveis (r, θ, ϕ) pode ser orientado de forma que o ponto inicial A esteja situado na posição $A = (r', \theta', \phi')$ e o ponto B esteja na posição $B = (r' + dr', \theta', \phi')$[iv]. Assim, o intervalo espacial $\sqrt{d\sigma^2} = \sqrt{dr^2 + S_k^2(r)\left(d\theta^2 + \sin^2\theta d\phi^2\right)}$ entre esses pontos reduz-se a $d\sigma = dr'$ e

$$d_p(t) = a(t) \int_0^r dr' \Rightarrow d_p(t) = a(t)r. \tag{2.8}$$

[iv] Para que a condição do tempo fixo seja satisfeita, a distância entre os pontos deve ser pequena o suficiente para que a expansão espacial seja desprezível.

É possível ainda escrever 2.8 em termos da coordenada x ao se inverter a equação 2.5:

$$d_p(t) = a(t)r(x) = a(t)\begin{cases} R_0 \arcsin(x/R_0) \\ x \\ R_0 \operatorname{arcsinh}(x/R_0) \end{cases} \quad \text{para } k = \begin{cases} +1 \\ 0 \\ -1 \end{cases} \tag{2.9}$$

Parâmetro de Hubble

Como a distância própria evolui ao longo do tempo, é possível obter a velocidade de afastamento devido à expansão do espaço por meio da sua derivada temporal:

$$\dot{d}_p(t) = \dot{a}(t)r. \tag{2.10}$$

Reescrevendo a equação 2.10, tem-se:

$$v_p(t) = H(t)d_p(t), \tag{2.11}$$

onde $v_p \equiv \dot{d}_p$ é a velocidade de afastamento devido à expansão do espaço e $H(t) \equiv \frac{\dot{a}(t)}{a(t)}$ é o parâmetro de Hubble, que quantifica a taxa de expansão espacial. Quando no tempo atual, esse parâmetro é chamado de constante de Hubble e a equação 2.11 torna-se:

$$v_p(t_0) = H_0 d_p(t_0), \tag{2.12}$$

o que corresponde à relação encontrada por Hubble (1929) [16] em suas medidas da velocidade de recessão de galáxias. É comum definir também uma constante de Hubble adimensional h tal que

$$H_0 = 100h\,\mathrm{km/s/Mpc}. \tag{2.13}$$

Redshift Cosmológico

O *redshift* é uma medida do deslocamento do comprimento de onda observado em relação ao comprimento de onda emitido:

$$z \equiv \frac{\lambda_{observado} - \lambda_{emitido}}{\lambda_{emitido}}. \tag{2.14}$$

A energia de um fóton pode ser mensurada a partir de seu comprimento de onda:

$$E = \frac{hc}{\lambda}. \tag{2.15}$$

Entretanto, conforme o Universo se expande, esse comprimento de onda também se

altera. Considerando uma fonte de luz, a frente de onda emitida em um tempo $t = t_{em}$ viajará no espaço até que seja observada no tempo $t = t_0$[v]. A métrica espaço-temporal para eventos tipo luz é $ds^2 = 0$ e o sistema de coordenadas espaciais que descrevem seu movimento pode ser orientado de forma que θ e ϕ permaneçam constantes. Desta forma, a equação 2.4 para este caso se reduzirá a

$$0 = -c^2dt^2 + a^2(t)dr^2 \Rightarrow cdt = a(t)dr. \tag{2.16}$$

Integrando ambos os lados da equação 2.16:

$$r = \int_0^r dr = c\int_{t_{em}}^{t_0} \frac{dt}{a(t)}. \tag{2.17}$$

A frente de onda seguinte será emitida no tempo $t = t_{em} + \frac{\lambda_{em}}{c}$ e observada no tempo $t = t_0 + \frac{\lambda_0}{c}$, em que λ_{em} e λ_0 são os comprimentos de onda nos momentos de emissão e observação, respectivamente. Desta forma, tem-se:

$$r = \int_0^r dr = c\int_{t_{em}+\frac{\lambda_{em}}{c}}^{t_0+\frac{\lambda_0}{c}} \frac{dt}{a(t)}. \tag{2.18}$$

Combinando as equações 2.17 e 2.18 e separando os intervalos de integração:

$$\int_{t_{em}}^{t_{em}+\frac{\lambda_{em}}{c}} \frac{dt}{a(t)} + \int_{t_{em}+\frac{\lambda_{em}}{c}}^{t_0} \frac{dt}{a(t)} = \int_{t_{em}+\frac{\lambda_{em}}{c}}^{t_0} \frac{dt}{a(t)} + \int_{t_0}^{t_0+\frac{\lambda_0}{c}} \frac{dt}{a(t)}. \tag{2.19}$$

Para intervalos de tempo entre as frentes de onda $\delta t_{em} = \frac{\lambda_{em}}{c}$ e $\delta t_0 = \frac{\lambda_0}{c}$ pequenos o suficiente, o fator de escala pode ser considerado fixo entre uma frente e outra. Assim,

$$\int_{t_{em}}^{t_{em}+\frac{\lambda_{em}}{c}} \frac{dt}{a(t_{em})} = \int_{t_0}^{t_0+\frac{\lambda_0}{c}} \frac{dt}{a(t_0)}. \tag{2.20}$$

Efetuando esta integração, obtém-se:

$$\frac{1}{a(t_{em})}\left[t_{em} + \frac{\lambda_{em}}{c} - t_{em}\right] = \frac{1}{a(t_0)}\left[t_0 + \frac{\lambda_0}{c} - t_0\right]. \tag{2.21}$$

Simplificando a equação anterior, é possível ver como os comprimentos de onda observado e emitido relacionam-se:

$$\lambda_{em} = a(t_{em})\lambda_0. \tag{2.22}$$

[v] Neste caso, a distância dos objetos e, consequentemente o tempo de viagem da luz $\Delta t = t_0 - t_{em} = \Delta l/c$, é grande o suficiente para que o fator de escala evolua neste intervalo de tempo.

Substituindo esse resultado na equação 2.14, obtém-se o *redshift* cosmológico, que ocorre quando o deslocamento é causado pela expansão do Universo:

$$1+z=\frac{1}{a(t_{em})}. \tag{2.23}$$

O *redshift* cosmológico constitui-se como uma valiosa ferramenta para conhecer, a partir de medidas observacionais, informações sobre o tempo e o tamanho do Universo em que uma emissão ocorreu.

2.1.2 Dinâmica de um Universo em Expansão

Equações de Friedmann

As equações de campo propostas por Einstein em 1915 podem ser descritas por:

$$G_{\mu\nu}+\Lambda g_{\mu\nu}=\frac{8\pi G}{c^4}T_{\mu\nu}, \tag{2.24}$$

em que $G_{\mu\nu}=R_{\mu\nu}-\frac{1}{2}g^{\mu\nu}R_{\mu\nu}g_{\mu\nu}$ é o tensor de Einstein, que mensura a curvatura espaço-temporal do Universo (Baumann, 2022 [1]), Λ é a constante cosmológica [vi], $g_{\mu\nu}$ é o tensor métrico e $T_{\mu\nu}$ é o tensor energia-momento, que descreve a composição do Universo em matéria e energia. Dado que o Universo é isotrópico, ele deve ser o mesmo que para um fluido perfeito em um sistema em repouso, podendo ser escrito como

$$T_{\mu\nu}=\left(\rho+\frac{P}{c^2}\right)U_\mu U_\nu+Pg_{\mu\nu}, \tag{2.25}$$

onde ρc^2 é a densidade de energia, P é a pressão do fluido e $U^\mu=\gamma(c,\mathbf{u})=\gamma(c,0,0,0)$[vii] é a quadrivelocidade em relação a um observador comóvel. Para um universo que segue a métrica de Robertson-Walker (2.1),

$$g_{\mu\nu}=\begin{pmatrix}-1 & 0 & 0 & 0\\ 0 & \dfrac{a^2(t)}{1-Kx^2} & 0 & 0\\ 0 & 0 & a^2(t)x^2 & 0\\ 0 & 0 & 0 & a^2(t)x^2\sin^2\theta\end{pmatrix}. \tag{2.26}$$

[vi] Inicialmente introduzida por Einstein para satisfazer a ideia de um universo estático, atualmente associada à energia escura e à aceleração da expansão do Universo.

[vii] A isotropia requer a ausência de direções preferenciais, logo as componentes espaciais da quadrivelocidade u^i desse fluido devem ser nulas para um observador em uma posição fixa.

De forma que o tensor energia-momento se torna

$$T_{\mu\nu} = \left(\rho + \frac{P}{c^2}\right) g_{\mu\nu} U^\mu U_\nu + P g_{\mu\nu} = -\left(\rho c^2 + P\right) g_{00} + P g_{\mu\nu}, \tag{2.27}$$

onde as componentes não-nulas serão:

$$T_{00} = \rho c^2, \qquad T_{ii} = P g_{ii} \qquad \{i = 1, 2, 3\}. \tag{2.28}$$

O tensor de Einstein $G_{\mu\nu}$ apresentado anteriormente é escrito em termos da métrica $g_{\mu\nu}$ e do tensor de Ricci, $R_{\mu\nu}$. Esse tensor, por sua vez, pode ser obtido a partir dos símbolos de Christoffel, $\Gamma^\mu_{\alpha\beta} \equiv \frac{1}{2} g^{\mu\lambda} \left(\partial_\alpha g_{\beta\lambda} + \partial_\beta g_{\alpha\lambda} - \partial_\lambda g_{\alpha\beta}\right)$:

$$R_{\mu\nu} \equiv \partial_\lambda \Gamma^\lambda_{\mu\nu} - \partial_\nu \Gamma^\lambda_{\mu\lambda} + \Gamma^\lambda_{\lambda\rho} \Gamma^\rho_{\mu\nu} - \Gamma^\rho_{\mu\lambda} \Gamma^\lambda_{\nu\rho}. \tag{2.29}$$

Desenvolvendo os símbolos de Christoffel para o sistema de coordenadas descrito pela métrica da equação 2.26, observa-se que termos em que $\mu \neq \lambda$ conduzem a valores nulos [viii], portanto:

$$\Gamma^\lambda_{\alpha\beta} = \frac{1}{2} g^{\lambda\lambda} \left(\partial_\alpha g_{\beta\lambda} + \partial_\beta g_{\alpha\lambda} - \partial_\lambda g_{\alpha\beta}\right). \tag{2.30}$$

Analogamente, termos em que $\lambda \neq \alpha \neq \beta$ também conduzem a valores nulos. Além disso, pode-se verificar que $\Gamma^\lambda_{\alpha\beta} = \Gamma^\lambda_{\beta\alpha}$ – ou seja, esse tensor é simétrico. Assim, os casos não-nulos dos símbolos de Christoffel se resumem a:

$$\Gamma^\lambda_{\lambda\beta} = \Gamma^\lambda_{\beta\lambda} = \frac{1}{2} g^{\lambda\lambda} \partial_\beta g_{\lambda\lambda}, \qquad \Gamma^\lambda_{\lambda\lambda} = \frac{1}{2} g^{\lambda\lambda} \partial_\lambda g_{\lambda\lambda}, \qquad \Gamma^\lambda_{\alpha\alpha} = -\frac{1}{2} g^{\lambda\lambda} \partial_\lambda g_{\alpha\alpha}. \tag{2.31}$$

Analisando a métrica em 2.26, é possível ver que termos do tipo $\partial_\alpha g_{00}$, $\partial_3 g_{\beta\beta}$, $\partial_2 g_{11}$, $\partial_2 g_{22}$, serão nulos – e consequentemente os símbolos de Christoffel Γ^λ_{00}, $\Gamma^0_{\beta 0} = \Gamma^0_{0\beta}$, $\Gamma^3_{\alpha\alpha}$, $\Gamma^\lambda_{3\lambda} = \Gamma^\lambda_{\lambda 3}$, Γ^2_{11}, $\Gamma^1_{12} = \Gamma^1_{21}$ e Γ^2_{22} também o serão. Os demais assumirão os valores:

- $\Gamma^0_{11} = -\frac{1}{2} g^{00} \partial_0 g_{11} = -\frac{1}{2}(-1) \frac{2a\dot{a}}{c(1-Kx^2)} = \frac{a\dot{a}}{c(1-Kx^2)}$
- $\Gamma^0_{22} = -\frac{1}{2} g^{00} \partial_0 g_{22} = -\frac{1}{2}(-1) \frac{2x^2 a\dot{a}}{c} = \frac{x^2 a\dot{a}}{c}$
- $\Gamma^0_{33} = -\frac{1}{2} g^{00} \partial_0 g_{33} = -\frac{1}{2}(-1) \frac{2x^2 a\dot{a} \sin^2\theta}{c} = \frac{x^2 a\dot{a} \sin^2\theta}{c}$
- $\Gamma^1_{01} = \Gamma^1_{10} = \frac{1}{2} g^{11} \partial_0 g_{11} = \frac{1}{2} \frac{(1-Kx^2)}{a^2} \frac{2a\dot{a}}{c(1-Kx^2)} = \frac{\dot{a}}{ac}$

[viii] Como $g^{\mu\nu} g_{\mu\nu} = \delta^\mu_\nu$, para a métrica apresentada em 2.26, $g^{\mu\nu} = 0$ quando $\mu \neq \lambda$ e $g^{\mu\nu} = \frac{1}{g_{\mu\nu}}$ quando $\mu = \lambda$.

- $\Gamma^1_{11} = \frac{1}{2}g^{11}\partial_1 g_{11} = \frac{1}{2}\frac{(1-Kx^2)}{a^2}\frac{2Kxa^2}{(1-Kx^2)^2} = \frac{Kx}{(1-Kx^2)}$
- $\Gamma^1_{22} = -\frac{1}{2}g^{11}\partial_1 g_{22} = -\frac{1}{2}\frac{(1-Kx^2)}{a^2}2xa^2 = -x(1-Kx^2)$
- $\Gamma^1_{33} = -\frac{1}{2}g^{11}\partial_1 g_{33} = -\frac{1}{2}\frac{(1-Kx^2)}{a^2}2xa^2\sin^2\theta = -x\sin^2\theta(1-Kx^2)$
- $\Gamma^2_{20} = \Gamma^2_{02} = \frac{1}{2}g^{22}\partial_0 g_{22} = \frac{1}{2}\frac{1}{x^2a^2}\frac{2x^2a\dot{a}}{c} = \frac{\dot{a}}{ac}$
- $\Gamma^2_{21} = \Gamma^2_{12} = \frac{1}{2}g^{22}\partial_1 g_{22} = \frac{1}{2}\frac{1}{x^2a^2}2xa^2 = \frac{1}{x}$
- $\Gamma^2_{33} = -\frac{1}{2}g^{22}\partial_2 g_{33} = -\frac{1}{2}\frac{1}{x^2a^2}2x^2a^2\sin\theta\cos\theta = -\sin\theta\cos\theta$
- $\Gamma^3_{30} = \Gamma^3_{03} = \frac{1}{2}g^{33}\partial_0 g_{33} = \frac{1}{2}\frac{1}{x^2a^2\sin^2\theta}\frac{2x^2a\dot{a}\sin^2\theta}{c} = \frac{\dot{a}}{ac}$
- $\Gamma^3_{31} = \Gamma^3_{13} = \frac{1}{2}g^{33}\partial_1 g_{33} = \frac{1}{2}\frac{1}{x^2a^2\sin^2\theta}2xa^2\sin^2\theta = \frac{1}{x}$
- $\Gamma^3_{32} = \Gamma^3_{23} = \frac{1}{2}g^{33}\partial_2 g_{33} = \frac{1}{2}\frac{1}{x^2a^2\sin^2\theta}2x^2a^2\sin\theta\cos\theta = \cot\theta$

Ademais, o tensor de Ricci também é um tensor simétrico ($R_{\mu\nu} = R_{\nu\mu}$), o que reduz o número de componentes a serem calculadas. Calculando as componentes não-nulas desse tensor a partir dos símbolos de Christoffel, obtém-se:

$$R_{00} = -\frac{3}{c^2}\frac{\ddot{a}}{a}, \qquad R_{ii} = \frac{(a\ddot{a}+2\dot{a}^2+2Kc^2)}{a^2c^2}g_{ii} \qquad \{i=1,2,3\}. \tag{2.32}$$

O termo $g^{\mu\nu}R_{\mu\nu}$ contido no tensor de Einstein $G_{\mu\nu}$ é chamado de escalar de Ricci. Ao calculá-lo para a métrica apresentada anteriormente, obtém-se:

$$g^{\mu\nu}R_{\mu\nu} = \frac{6}{c^2}\left[\frac{\ddot{a}}{a} + \left(\frac{\dot{a}}{a}\right)^2 + \frac{kc^2}{R_0^2a^2}\right]. \tag{2.33}$$

Portanto, as componentes do tensor de Einstein serão

$$G_{00} = \frac{3}{c^2}\left[\left(\frac{\dot{a}}{a}\right)^2 + \frac{kc^2}{R_0^2a^2}\right], \quad G_{ii} = -\frac{1}{c^2}\left[\frac{2\ddot{a}}{a} + \left(\frac{\dot{a}}{a}\right)^2 + \frac{kc^2}{R_0^2a^2}\right]g_{ii} \quad \{i=1,2,3\}. \tag{2.34}$$

Inserindo os resultados de 2.28 e 2.34 em 2.24, obtém-se, para a parte temporal ($\mu = \nu = 0$):

$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{8\pi G}{3c^2}\rho c^2 - \frac{kc^2}{R_0^2a^2} + \frac{\Lambda c^2}{3}, \tag{2.35}$$

a equação de Friedmann que descreve a evolução do fator de escala ao longo do tempo. Já para a parte espacial ($\mu = \nu = 1,2,3$), encontra-se

$$\frac{\ddot{a}}{a} = -\frac{4\pi G}{c^2}P + \frac{\Lambda c^2}{2} - \frac{1}{2}\left(\frac{\dot{a}}{a}\right)^2 - \frac{1}{2}\frac{kc^2}{R_0^2 a^2} \tag{2.36}$$

e, substituindo $\left(\frac{\dot{a}}{a}\right)^2$ encontrado em 2.35

$$\frac{\ddot{a}}{a} = -\frac{4\pi G}{3c^2}\left(\rho c^2 + 3P\right) + \frac{\Lambda c^2}{3}, \tag{2.37}$$

encontra-se a segunda das equações de Friedmann, que descreve a aceleração ou desaceleração do fator de escala em função da composição do Universo.

Equação de Continuidade

O Universo homogêneo e isotrópico está sujeito às leis de conservação de energia e momento locais, que podem ser expressas através da conservação da derivada covariante do tensor de energia-momento[ix]:

$$\nabla_\mu T^\mu_\nu = \partial_\mu T^\mu_\nu + \Gamma^\mu_{\alpha\mu} T^\alpha_\nu - \Gamma^\alpha_{\nu\mu} T^\mu_\alpha = 0. \tag{2.38}$$

A forma mista do tensor é dada por

$$T^\mu_\nu = g^{\mu\alpha} T_{\alpha\nu}, \tag{2.39}$$

portanto,

$$T^0_0 = -\rho c^2, \qquad T^i_i = P, \qquad \{i = 1,2,3\}, \tag{2.40}$$

e, aplicando este resultado – e os símbolos de Christoffel desenvolvidos anteriormente – na equação 2.38 para o caso em que $\nu = 0$:

$$\nabla_\mu T^\mu_0 = \partial_\mu T^\mu_0 + \Gamma^\mu_{\alpha\mu} T^\alpha_0 - \Gamma^\alpha_{0\mu} T^\mu_\alpha = \partial_0 T^0_0 + \Gamma^i_{0i} T^0_0 - \Gamma^i_{0i} T^i_i = -\dot{\rho} c - 3\frac{\dot{a}}{a}\rho c - 3\frac{\dot{a}}{a}\frac{P}{c} = 0. \tag{2.41}$$

Ou ainda,

$$\dot{\rho} c^2 + 3\frac{\dot{a}}{a}\left(\rho c^2 + P\right) = 0, \tag{2.42}$$

a equação de continuidade da Relatividade Geral.

[ix] A conservação de energia – que será abordada no desenvolvimento desta subseção – refere-se à $\nu = 0$, enquanto a conservação do momento é descrita por $\nu = i$, em que i assume os valores de 1 a 3.

Equação de Estado

O termo $\rho c^2 = \varepsilon$ contido nas equações 2.35, 2.37 e 2.42 corresponde à densidade de energia das diferentes componentes do Universo. Ela pode ser decomposta como uma soma das densidades de energia destas componentes:

$$\varepsilon = \sum_i \varepsilon_i \tag{2.43}$$

Dado que estas componentes que comportam-se como um fluido perfeito, é possível relacionar a densidade de energia ε_i e a pressão P_i através de uma equação de estado:

$$P_i = w_i \varepsilon_i, \tag{2.44}$$

em que w_i é uma quantidade adimensional que assume diferentes valores a depender da componente a ser considerada. Ademais, fica evidente que a pressão P também pode ser decomposta nas diferentes componentes, ou seja,

$$P = \sum_i P_i = \sum_i w_i \varepsilon_i. \tag{2.45}$$

Alguns valores de interesse para w_i são $w_m = 0$ para componentes não-relativísticas, tais como a matéria bariônica, elétrons e a matéria escura [x] e $w_r = \frac{1}{3}$ para componentes com velocidades comparáveis à velocidade da luz, como fótons e neutrinos [xi] (Ryden, 2017 [23]).

Constante Cosmológica

Na equação 2.24, a constante cosmológica encontra-se do lado esquerdo da equação, o que condiz com uma interpretação geométrica deste termo. Porém, é possível reinterpretá-lo como estando relacionado a um fluido com densidade de energia constante, de forma que a equação de Einstein se torna

$$G_{\mu\nu} = \frac{8\pi G}{c^4} T_{\mu\nu} - \Lambda g_{\mu\nu} = \frac{8\pi G}{c^4}(T_{\mu\nu} - T^{(\Lambda)}_{\mu\nu}), \tag{2.46}$$

onde

$$T^{(\Lambda)}_{00} = \frac{\Lambda c^4}{8\pi G}, \qquad T^{(\Lambda)}_{ii} = -\frac{\Lambda c^4}{8\pi G} g_{ii} \qquad \{i = 1,2,3\}. \tag{2.47}$$

[x] comumente referidas como matéria, o que justifica o índice m utilizado.
[xi] chamadas de radiação, razão para o índice r utilizado.

Ou ainda, escrevendo $\rho_\Lambda c^2 = \frac{\Lambda c^4}{8\pi G}$ e $P_\Lambda = -\frac{\Lambda c^4}{8\pi G} = -\rho_\Lambda c^2 = w_\Lambda \varepsilon_\Lambda$, com $w_\Lambda = -1$, é possível embutir estes termos nas equações 2.43 e 2.45, permitindo dispor a equação de Einstein como

$$G_{\mu\nu} = \frac{8\pi G}{c^4} T_{\mu\nu} \tag{2.48}$$

e reescrever as equações de Friedmann na forma:

$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{8\pi G}{3c^2}\rho c^2 - \frac{kc^2}{R_0^2 a^2}, \tag{2.49}$$

$$\frac{\ddot{a}}{a} = -\frac{4\pi G}{3c^2}\left(\rho c^2 + 3P\right). \tag{2.50}$$

Evolução das Densidades de Energia

A partir da equação de estado (2.45) e da equação de continuidade (2.42), é possível decompor a equação de estado para as diferentes componentes e obter sua evolução da densidade de energia em função do fator de escala:

$$\frac{\dot{\varepsilon}_i}{\varepsilon_i} = -3\frac{\dot{a}}{a}(1+w_i) \Leftrightarrow \frac{d\left(\ln \varepsilon_i\right)}{dt} = -3(1+w_i)\frac{d\left(\ln a\right)}{dt}. \tag{2.51}$$

Integrando ambos os lados da equação, obtém-se

$$\varepsilon_i(a) = C_i a^{-3(1+w_i)}, \tag{2.52}$$

onde Ci é uma constante de integração. Dado que $a(t_0) = 1$, então $\varepsilon_{i,0} = \varepsilon_i(a(t_0)) = C_i$ e portanto,

$$\varepsilon_i(a) = \varepsilon_{i,0} a^{-3(1+w_i)}, \tag{2.53}$$

o que significa que a densidade de energia cai com o aumento do fator de escala a uma taxa determinada pelo parâmetro w_i. Para a matéria ($w_m = 0$), tem-se

$$\varepsilon_m(a) = \varepsilon_{m,0} a^{-3}. \tag{2.54}$$

Para a radiação $\left(w_r = \frac{1}{3}\right)$, obtém-se

$$\varepsilon_r(a) = \varepsilon_{r,0} a^{-4}. \tag{2.55}$$

Já para a constante cosmológica ($w_\Lambda = -1$), o resultado é

$$\varepsilon_\Lambda = \varepsilon_{\Lambda,0}, \tag{2.56}$$

o que reflete a característica desta densidade de ser constante ao longo do tempo.

A figura 2.2 representa graficamente a evolução destas densidades em função do fator de escala, permitindo verificar também que a componente com maior densidade muda conforme o Universo se expande. O período em que uma certa componente domina sobre as outras é chamado de era.

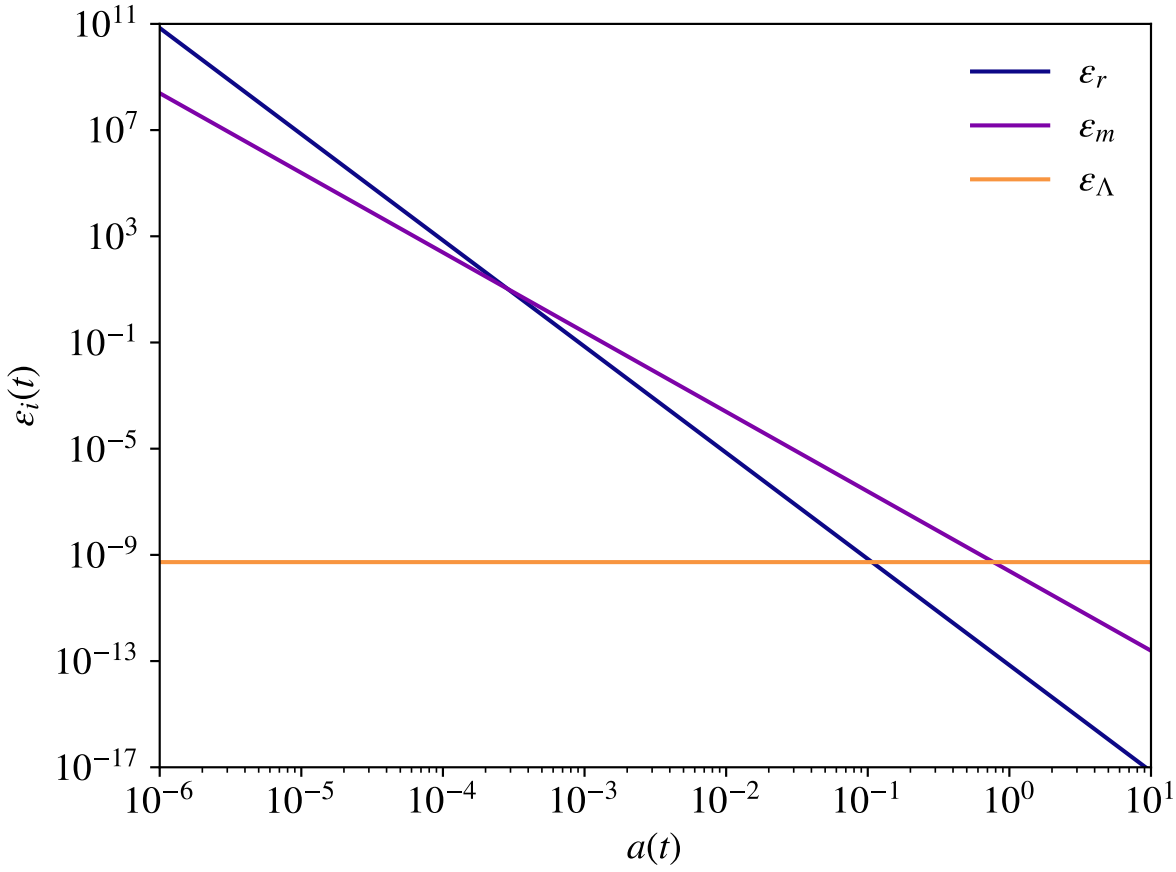

Figura 2.2: Evolução das densidades de radiação, matéria e constante cosmológica.

Densidade Crítica

Conforme mencionado anteriormente, a constante k fornece informações acerca da geometria espacial do Universo. Desta forma, é possível definir, a partir da equação de Friedmann (2.49), uma densidade para um universo plano, em que $k = 0$:

$$\varepsilon_c(t) = \frac{3c^2H^2(t)}{8\pi G}. \tag{2.57}$$

No momento atual ($t = t_0$), a densidade crítica presente $\varepsilon_{c,0}$ é dada por

$$\varepsilon_{c,0} = \frac{3c^2H_0^2}{8\pi G}. \tag{2.58}$$

É possível ainda reescrever a equação de Friedmann 2.49 de forma a entender como a geometria do Universo relaciona-se com a densidade e a densidade crítica:

$$\varepsilon(t) = \varepsilon_c(t)\left(1 + k\frac{c^2}{H^2 R_0^2 a^2}\right). \tag{2.59}$$

Dado que os termos que acompanham k são positivos, então, para densidades maiores que a densidade crítica $(\varepsilon(t) > \varepsilon_c(t))$, k deve ser positivo, correspondendo a um universo esférico, curvado positivamente; para densidades menores que a densidade crítica $(\varepsilon(t) < \varepsilon_c(t))$, k será negativo, correspondendo a um universo negativamente curvado, hiperbólico; um universo plano $(k = 0)$ corresponde a uma densidade igual à densidade crítica.

Parâmetros de Densidade

A partir da densidade crítica é possível ainda obter os parâmetros de densidade, que correspondem às densidades relativas das componentes do Universo em relação à densidade crítica:

$$\Omega(t) = \sum_i \Omega_i(t), \qquad \Omega_i(t) = \frac{\varepsilon_i(t)}{\varepsilon_c(t)}, \qquad \{i = m, r, \Lambda\}. \tag{2.60}$$

Em $t = t_0$, é possível definir parâmetros de densidade para o tempo presente:

$$\Omega_0 = \sum_i \Omega_{i,0}, \qquad \Omega_{i,0} = \frac{\varepsilon_{i,0}}{\varepsilon_{c,0}}, \qquad \{i = m, r, \Lambda\}. \tag{2.61}$$

O que torna possível reescrever o parâmetro de densidade em função do tempo de cada componente como

$$\Omega_i(t) = \frac{\varepsilon_i(t)}{\varepsilon_c(t)} = \frac{\varepsilon_{i,0} a^{-3(1+w_i)}}{\varepsilon_{c,0}\frac{H^2(t)}{H_0^2}} = \Omega_{i,0} a^{-3(1+w_i)} \frac{H_0^2}{H^2(t)}, \qquad \{i = m, r, \Lambda\}. \tag{2.62}$$

Reorganizando a equação 2.59 em termos de $\Omega(t)$, têm-se:

$$\Omega(t) = 1 - \Omega_k(t), \tag{2.63}$$

onde

$$\Omega_k(t) = -\frac{kc^2}{R_0^2 H^2(t) a^2(t)} \tag{2.64}$$

é um parâmetro de "densidade" para a curvatura, que permite quantificar o grau de curvatura do Universo. No tempo $t = t_0$:

$$\Omega_{k,0} = -\frac{kc^2}{R_0^2 H_0^2}. \tag{2.65}$$

Assim, Ω_k pode ser escrito como

$$\Omega_k(t) = \Omega_{k,0} a^{-2} \frac{H_0^2}{H^2(t)}. \tag{2.66}$$

Escrevendo os parâmetros de curvatura de cada componente explicitamente, a equação 2.63 torna-se:

$$\Omega_m(t) + \Omega_r(t) + \Omega_\Lambda(t) + \Omega_k(t) = 1. \tag{2.67}$$

Ou, em termos dos parâmetros de densidade no tempo t_0, da constante e do parâmetro de Hubble:

$$\frac{H^2(t)}{H_0^2} = \Omega_{m,0} a^{-3} + \Omega_{r,0} a^{-4} + \Omega_{\Lambda,0} + \Omega_{k,0} a^{-2}. \tag{2.68}$$

Ademais, vale salientar que a densidade de matéria (ρ_m) contém componentes de matéria bariônica (ρ_b), e matéria escura fria (ρ_c), de forma que o parâmetro de densidade da matéria total $\Omega_m(t)$ pode ser decomposto nos parâmetros de densidade de seus componentes:

$$\Omega_m(t) = \Omega_b(t) + \Omega_c(t). \tag{2.69}$$

Já a densidade de radiação agrupa as densidades de fótons (ρ_γ) – provenientes principalmente da Radiação Cósmica de Fundo – e de neutrinos (ρ_ν):

$$\Omega_r(t) = \Omega_\gamma(t) + \Omega_\nu(t). \tag{2.70}$$

2.1.3 Recombinação e Desacoplamento

O Universo descrito pelo modelo FLRW examinado nas seções anteriores condiz com um estado de altas densidades e temperaturas em seus momentos iniciais. Conforme ele se expande, essas densidades e temperaturas decrescem – como pode ser visualizado na figura 2.2 –, permitindo a ocorrência de processos como a Recombinação e o Desacoplamento, descritos nas seções a seguir.

Para a abordagem exposta a seguir, será considerado um universo aproximadamente plano – em que $\Omega_k \sim 0$ –, composto apenas por átomos de Hidrogênio e cujo número total de elétrons é igual ao número total de prótons – um universo neutro.

Recombinação

A energia necessária para que um fóton ionize um átomo de Hidrogênio é de $13,6\,\mathrm{eV}$. No Universo Primordial, em que as energias dos fótons existentes eram muito mais altas, todos os elétrons e prótons encontravam-se livres, isto é, a reação de sua combinação – descrita pelo

sentido inverso da equação 2.71 abaixo – era altamente desfavorecida.

$$H + \gamma \rightleftharpoons p^+ + e^- \tag{2.71}$$

Com a expansão e resfriamento do Universo, há uma diminuição na energia dos fótons, o que aumenta as chances da combinação de um próton e um elétron em um átomo de Hidrogênio não ser desfeita por meio de uma fotoionização – processo que corresponde ao sentido direto da equação 2.71. Assim, a fração de átomos de Hidrogênio em relação ao número total de partículas aumenta gradualmente, até que o Universo esteja totalmente não ionizado.

Dado que o número total de prótons é igual ao número total de elétrons, a densidade numérica de bárions n_b, que corresponde ao número de partículas em um determinado volume, é descrita por:

$$n_b = n_p + n_H = n_e + n_H, \tag{2.72}$$

onde n_p é a densidade numérica de prótons livres, ainda não combinados, n_e é a densidade numérica de elétrons livres e n_H é a densidade numérica de átomos de Hidrogênio.

A partir das densidades numéricas e da relação mencionadas, é possível definir a ionização fracionária, uma fração X que representa o grau de ionização do Universo, isto é, quantos pares de partículas encontram-se livres em relação ao número total de pares, tal que

$$X = \frac{n_e}{n_b} = \frac{n_p}{n_b} = \frac{n_p}{n_p + n_H}, \tag{2.73}$$

ou ainda,

$$1 - X = \frac{n_H}{n_b} = \frac{n_H}{n_p + n_H}. \tag{2.74}$$

Enquanto não ocorre o desacoplamento, fótons, elétrons e prótons formam um gás de partículas à mesma temperatura e em equilíbrio térmico. Assim, é possível descrever as propriedades desse gás com o uso da Mecânica Estatística.

A densidade numérica de um gás ideal de partículas de uma espécie i obedece à distribuição

$$n_i(p)dp = g_i \frac{4\pi}{h^3} f_i(p,T) p^2 dp, \tag{2.75}$$

em que

$$f_i(p,T) = \frac{1}{e^{(E_i - \mu_i)/kT} \pm 1} \tag{2.76}$$

é a distribuição estatística dessas partículas. Caso essas partículas sejam bósons, a distribuição será a de Bose-Einstein e o sinal presente no denominador será negativo; caso elas sejam

férmions, será a de Fermi-Dirac, cujo sinal é positivo. Portanto, a equação 2.75 torna-se

$$n_i(p)dp = g_i \frac{4\pi}{h^3} \frac{p^2 dp}{e^{(E-\mu_i)/kT} \pm 1}, \tag{2.77}$$

em que g_i é o peso estatístico da partícula e μ_i é seu potencial químico, que quantifica a mudança na energia interna de um sistema ao se adicionar partículas a ele (Blundell e Blundell, 2017 [24]). Para fótons, elétrons e prótons, $g_i = 2$.

No equilíbrio, os potenciais químicos das espécies presentes na reação 2.71 se relacionarão através de

$$\mu_H + \mu_\gamma = \mu_p + \mu_e. \tag{2.78}$$

Entretanto, os fótons são partículas cujo número de partículas não é conservado por nenhuma lei fundamental, o que implica que seu potencial químico é $\mu_\gamma = 0$ (Blundell e Blundell, 2017 [24]). Consequentemente, a equação 2.78 se torna:

$$\mu_H = \mu_p + \mu_e. \tag{2.79}$$

Além disso, os fótons consistem em férmions cuja energia é $E = hf = pc$, portanto, a distribuição de sua densidade numérica se dá por

$$n_\gamma(f)df = \frac{8\pi}{c^3} \frac{f^2 df}{e^{hf/kT} - 1}, \tag{2.80}$$

Integrando este resultados para todas as frequências, obtém-se

$$n_\gamma = \frac{2,4041}{\pi^2} \left(\frac{kT}{\hbar c}\right)^3. \tag{2.81}$$

Para partículas bosônicas não-relativísticas como os prótons e elétrons e átomos na época da recombinação, a energia de repouso é muito maior que a energia cinética, o que torna válidas as desigualdades $m_i c^2 \gg pc$ e $E_i - \mu_i \gg kT$. Assim, é possível aproximar $E_i = \sqrt{m_i^2 c^4 + p^2 c^2}$ para $E_i \approx m_i c^2 + \frac{p^2}{2m_i}$.

Portanto, a equação 2.75 para essas partículas será

$$n_i(p)dp = g_i \frac{4\pi}{h^3} e^{(-m_i c^2 + \mu_i)/kT} e^{-p^2/2m_i kT} p^2 dp, \tag{2.82}$$

o que corresponde a uma distribuição de Maxwell-Boltzmann das velocidades das partículas. Integrando dentro do intervalo $p = 0$ a $p = \infty$, tem-se a densidade numérica para esse tipo de

partícula:

$$n_i = g_i \left(\frac{m_i kT}{2\pi\hbar^2} \right)^{3/2} \exp\left(\frac{-m_i c^2 + \mu_i}{kT} \right) \tag{2.83}$$

Como mencionado anteriormente, prótons e elétrons possuem $g_i = 2$, portanto $g_H = g_p \cdot g_e = 4$ e

$$n_H = 4 \left(\frac{m_H kT}{2\pi\hbar^2} \right)^{3/2} \exp\left(\frac{-m_H c^2 + \mu_H}{kT} \right), \tag{2.84}$$

$$n_p = 2 \left(\frac{m_p kT}{2\pi\hbar^2} \right)^{3/2} \exp\left(\frac{-m_p c^2 + \mu_p}{kT} \right), \tag{2.85}$$

$$n_e = 2 \left(\frac{m_e kT}{2\pi\hbar^2} \right)^{3/2} \exp\left(\frac{-m_e c^2 + \mu_e}{kT} \right). \tag{2.86}$$

Dividindo-se 2.84 por 2.85 e 2.86 e utilizando-se do resultado 2.79, obtém-se

$$\frac{n_H}{n_p n_e} = \left(\frac{m_H}{m_p m_e} \right)^{3/2} \left(\frac{2\pi\hbar^2}{kT} \right)^{3/2} \exp\left(\frac{Q}{kT} \right) \tag{2.87}$$

onde $Q = (-m_H + m_p + m_e)c^2 = 13,6\,\text{eV}$ é a energia de ionização do hidrogênio. Dado que a razão entre as massas do átomo de hidrogênio e do próton é aproximadamente igual a 1, é possível fazer esta aproximação e obter a equação de Saha:

$$\frac{n_H}{n_p n_e} = \left(\frac{2\pi\hbar^2}{m_e kT} \right)^{3/2} \exp\left(\frac{Q}{kT} \right) \tag{2.88}$$

A partir dos resultados obtidos em 2.73 e 2.74, pode-se reescrever a equação anterior como:

$$\frac{1-X}{X^2} = n_b \left(\frac{2\pi\hbar^2}{m_e kT} \right)^{3/2} \exp\left(\frac{Q}{kT} \right). \tag{2.89}$$

Ou ainda, definindo a fração entre bárions e fótons $\eta \equiv \frac{n_b}{n_\gamma}$:

$$\frac{1-X}{X^2} = 3,84\eta \left(\frac{kT}{m_e c^2} \right)^{3/2} \exp\left(\frac{Q}{kT} \right) = S(T,\eta), \tag{2.90}$$

que corresponde à equação quadrática

$$SX^2 + X - 1 = 0, \tag{2.91}$$

cujas soluções são

$$X_\pm = \frac{-1 \pm \sqrt{1+4S}}{2S}. \tag{2.92}$$

Dado que pela definição de X ele deve ser estritamente positivo, então a ionização fracionária

será

$$X = \frac{-1+\sqrt{1+4S}}{2S}. \tag{2.93}$$

O momento em que a recombinação ocorre é definido como $X = \frac{1}{2}$, o que corresponde a $S = 2$, ou ainda, para $\eta = 6,1 \cdot 10^{-10}$,

$$kT_{rec} = 0,324\,\text{eV} = \frac{Q}{42}. \tag{2.94}$$

Isto corresponde a um *redshift* de $z_{rec} \approx 1380$.

Desacoplamento

Como visto na seção 2.1.2, as densidades de matéria e radiação caem com o fator de escala. No início do Universo – a um fator de escala muito pequeno –, as densidades eram altas o bastante para que a radiação e a matéria bariônica – principalmente elétrons livres – interagissem frequentemente através do espalhamento Thomsom, termalizando sua temperatura. Isto corresponde ao estado de acoplamento entre matéria e radiação.

A taxa a qual essa interação ocorre pode ser descrita por [xii]

$$\Gamma(z) = n_e(z)\sigma_e c, \tag{2.95}$$

em que c é a velocidade da luz, $\sigma_e = 6,65 \cdot 10^{-29}\,\text{m}^2$ é a seção transversal para o espalhamento Thomsom e $n_e(z)$ é a densidade numérica de elétrons livres. Conforme visto na seção anterior, esta densidade relaciona-se com a densidade de bárions através de $n_e = Xn_b$. Assim, sabendo que a densidade de bárions evolui da mesma forma que a densidade de matéria, é possível reescrever a equação 2.95

$$\Gamma(z) = X(z)n_{b,0}a^{-3}\sigma_e c = X(z)(1+z)^3 n_{b,0}\sigma_e c \tag{2.96}$$

É visível que, ao passo em que o Universo se expande, esta taxa de interações decai. Enquanto os fótons estão acoplados, $\Gamma > H$. Quando $\Gamma < H$, é dito que os fótons encontram-se desacoplados. O momento de transição, em que $\Gamma = H$, é chamado de desacoplamento. A partir deste momento, as interações entre fótons e elétrons tornam-se muito menos frequentes.

No momento em que o desacoplamento ocorre, o Universo era dominado pela matéria.

[xii] É válido comentar que $\frac{1}{n_e(z)\sigma_e}$ corresponde ao livre caminho médio de um fóton, a distância média que ele percorre antes que ocorra uma interação.

Assim, considerando apenas a componente da matéria na equação 2.68, tem-se[xiii]

$$H(z) = H_0\sqrt{\Omega_{m,0}}(1+z)^{3/2}, \tag{2.97}$$

permitindo encontrar o momento em que o desacoplamento ocorre:

$$z_{dec} = \left(\frac{H_0\sqrt{\Omega_{m,0}}}{X(z)n_{b,0}\sigma_e c}\right)^{2/3} - 1 \approx 1100 \tag{2.98}$$

Profundidade Ótica

Dada que a interação de espalhamento dos fótons é descrita pela taxa $\Gamma(t)$, é possível definir uma probabilidade de que o espalhamento ocorra, $d\tau = \Gamma(t)dt$. A partir desta probabilidade, é definida a profundidade ótica (τ):

$$\tau(t_{inicial}) = \int_{t_{inicial}}^{t_{final}} \Gamma(t)dt, \tag{2.99}$$

uma medida adimensional do quanto a luz consegue penetrar em um determinado meio. Quando $\tau = 0$, o meio é dito oticamente fino e toda luz que adentra nele é transmitida. Quando $\tau = 1$, o meio é dito oticamente espesso ou opaco e a luz não consegue atravessá-lo.

Conforme já mencionado, antes do desacoplamento os fótons interagiam fortemente com os elétrons e, consequentemente, não conseguiam viajar por grandes distâncias no meio onde estavam, tornando o Universo opaco antes dessa época. Desta forma, a superfície de último espalhamento é uma casca esférica constituída pelos fótons observados em um determinado tempo $t_{final} = t_0$ e espalhados pela última vez no tempo em que ocorreu o último espalhamento, $t_{inicial} = t_{ls}$ [xiv], para o qual $\tau = 1$. Essa casca é o que constitui a Radiação Cósmica de Fundo, também chamada de Fundo Cósmico em Microondas, devido aos fótons observados estarem predominantemente nesta faixa do espectro eletromagnético. Mais detalhes sobre a CMB serão dados na seção 2.1.4.

Com o surgimento das primeiras estrelas, o Universo começa a se reionizar, fazendo com que o espalhamento dos fótons por elétrons livres torne-se provável novamente. A profundidade ótica – a partir da qual pode ser obtida o redshift – em que isso ocorre é então

$$\tau_{reio} = \tau(t_{reio}) = \int_{t_{reio}}^{t_0} \Gamma(t)dt, \tag{2.100}$$

chamada de profundidade ótica de reionização.

[xiii] O mais correto seria fazer a aproximação considerando as componentes da matéria e da radiação.
[xiv] Ressalta-se que este tempo não é o mesmo para todos os fótons

2.1.4 A Radiação Cósmica de Fundo

Antes do desacoplamento, os fótons interagiam frequentemente com a matéria, possibilitando sua termalização. Nesta condição, sua distribuição em frequências correspondia à de um corpo negro, como pode ser visto na equação 2.80.

Após a recombinação, o livre caminho médio dos fótons cresce bastante devido à diminuição no número de elétrons livres, ou seja, eles viajam por grandes distâncias sem interagir com a matéria. Além disso, após o desacoplamento estes fótons não mais encontram-se à mesma temperatura que a matéria e sua densidade numérica cai com $n \propto a^{-3}$, mantendo a forma de corpo negro de seu espectro (Baumann, 2022 [1]). Da equação 2.81, vê-se que a temperatura cai com a^{-1}. Assim, relacionando com a temperatura dos fótons no tempo presente ($T(t_0) = T_0$),

$$\frac{T(t)}{T_0} = \frac{1}{a(t)} \Rightarrow T(t) = \frac{T_0}{a(t)}. \tag{2.101}$$

Em 1965, Penzias e Wilson [8] observaram uma temperatura de ruído em suas medidas que era condizente com as características da radiação liberada após o desacoplamento. Medidas posteriores realizadas pelo instrumento FIRAS (*Far InfraRed Absolute Spectrophotometer*) do satélite COBE verificaram que a distribuição espectral de intensidades dessa radiação está de acordo com a distribuição esperada (Fixsen *et al.*, 1996 [10]), cuja temperatura média atual, medida pelo WMAP, é de $T_0 = 2,7255 \pm 0,0006\,\mathrm{K}$ (Fixsen, 2009. [2]). As médias das medidas de intensidade obtidas e a curva de corpo negro correspondente à temperatura atual dos fótons da CMB podem ser conferidas na figura 2.3.

Anisotropias de Temperatura

Além de verificar que a distribuição de temperaturas segue uma distribuição de corpo negro, as observações da CMB também permitiram a detecção de flutuações em sua temperatura da ordem de $\frac{\Delta T}{T} \sim 10^{-5}$ (Smoot *et al.*, 1992 [11]). O estudo estatístico dessas flutuações constituiu-se como um dos objetivos de missões espaciais voltadas à observação da CMB ao longo dos anos após sua descoberta.

É possível descrever a temperatura em uma determinada direção $\hat{\mathbf{n}}$ da esfera celeste mensurando o quanto ela se desvia da temperatura média ($\langle T \rangle$) através da flutuação de temperatura fracional $\frac{\delta T}{T}(\hat{\mathbf{n}})$:

$$\frac{\delta T}{T}(\hat{\mathbf{n}}) = \frac{T(\hat{\mathbf{n}}) - \langle T \rangle}{\langle T \rangle}. \tag{2.102}$$

Dado que estas temperaturas distribuem-se ao longo da esfera celeste, a melhor forma de se descrever estatisticamente estas variações de temperaturas é com uma expansão em termos dos

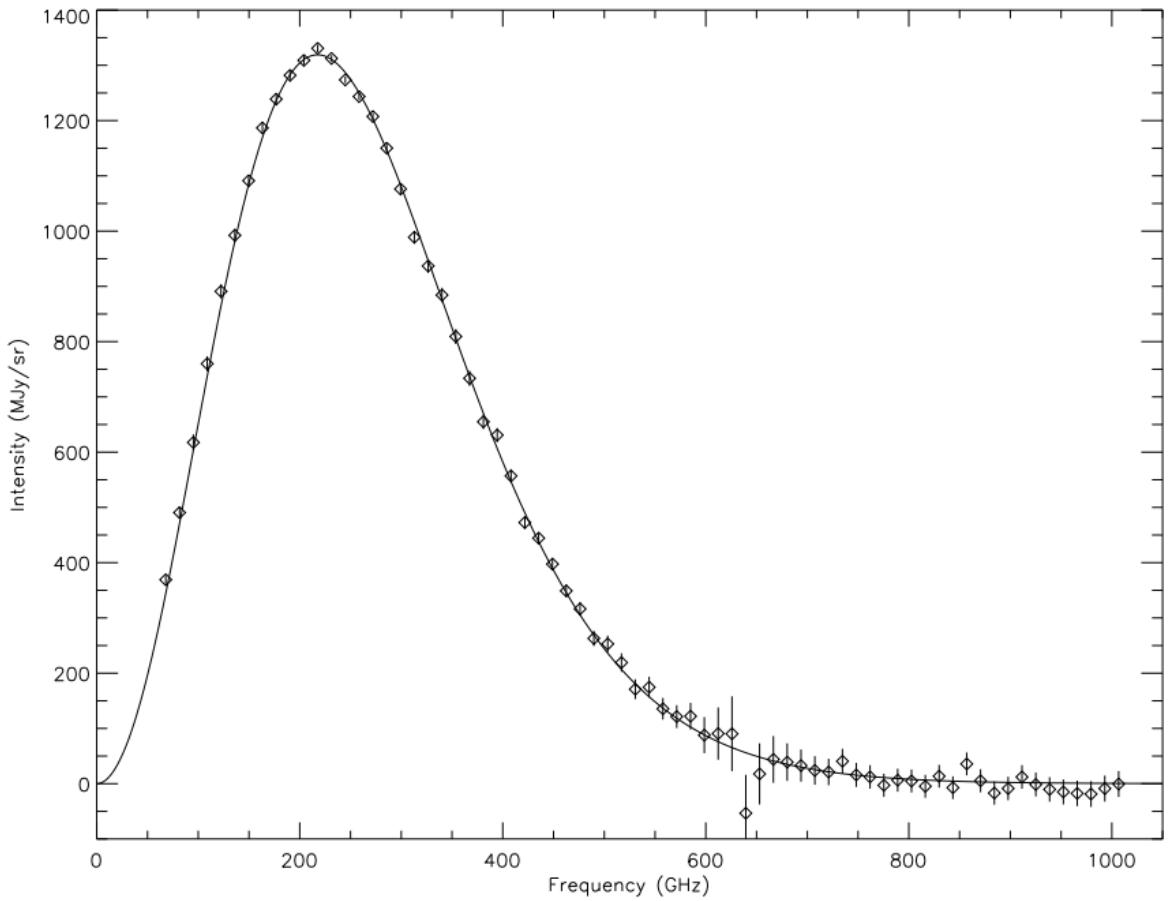

Figura 2.3: Medidas da intensidade média em função da frequência e curva de corpo negro fixada *a priori*. Retirado de Fixsen, 2009. [2]

harmônicos esféricos $Y_{\ell m}(\hat{\mathbf{n}})$:

$$\frac{\delta T}{T}(\hat{\mathbf{n}}) = \sum_{\ell=0}^{\infty} \sum_{m=-\ell}^{\ell} a_{\ell m} Y_{\ell m}(\hat{\mathbf{n}}), \tag{2.103}$$

onde os $a_{\ell m}$ são os coeficientes de expansão. Dado que os harmônicos esféricos satisfazem a condição de ortogonalidade (Arfken, Weber e Harris, 2007 [25])

$$\int Y_{\ell m}(\hat{\mathbf{n}}) Y^*_{\ell' m'}(\hat{\mathbf{n}}) d^2\hat{\mathbf{n}} = \delta_{\ell\ell'}\delta_{mm'}, \tag{2.104}$$

é possível obter o valor dos coeficientes de expansão multiplicando ambos os lados da equação 2.103 por $Y^*_{\ell' m'}$ e integrando:

$$\int \frac{\delta T}{T}(\hat{\mathbf{n}}) Y^*_{\ell' m'}(\hat{\mathbf{n}}) d^2\hat{\mathbf{n}} = \sum_{\ell=0}^{\infty} \sum_{m=-\ell}^{\ell} a_{\ell m} \int Y_{\ell m}(\hat{\mathbf{n}}) Y^*_{\ell' m'}(\hat{\mathbf{n}}) d^2\hat{\mathbf{n}}, \tag{2.105}$$

o que resulta em

$$\int \frac{\delta T}{T}(\hat{\mathbf{n}}) Y^*_{\ell' m'}(\hat{\mathbf{n}}) d^2\hat{\mathbf{n}} = \sum_{\ell=0}^{\infty} \sum_{m=-\ell}^{\ell} a_{\ell m} \delta_{\ell\ell'}\delta_{mm'}, \tag{2.106}$$

ou ainda,

$$a_{\ell m} = \int d(\hat{\mathbf{n}}) \frac{\delta T}{T}(\hat{\mathbf{n}}) Y^*_{\ell m}(\hat{\mathbf{n}}). \tag{2.107}$$

Função de Correlação

Para a análise estatística das flutuações, é útil introduzir uma função de correlação de dois pontos para as flutuações de temperatura:

$$C(\theta) = \left\langle \frac{\delta T}{T}(\hat{\mathbf{n}}) \frac{\delta T}{T}(\hat{\mathbf{n}}') \right\rangle \tag{2.108}$$

Dado que $\frac{\delta T}{T}(\hat{\mathbf{n}})$ é uma função real, então

$$\left(\frac{\delta T}{T}(\hat{\mathbf{n}}) \right)^* = \left(\frac{\delta T}{T}(\hat{\mathbf{n}}) \right) \tag{2.109}$$

e é possível estabelecer as relações:

$$a^*_{\ell m} = a_{\ell,-m}, \tag{2.110}$$

e

$$Y^*_{\ell m}(\hat{\mathbf{n}}) = Y_{\ell,-m}(\hat{\mathbf{n}}). \tag{2.111}$$

Assim, a função de correlação pode ser reescrita como

$$C(\theta) = \left\langle \frac{\delta T}{T}(\hat{\mathbf{n}}) \left(\frac{\delta T}{T}(\hat{\mathbf{n}}') \right)^* \right\rangle = \sum_{\ell=0}^{\infty} \sum_{m=-\ell}^{\ell} \langle a_{\ell m} a^*_{\ell' m'} \rangle Y_{\ell m}(\hat{\mathbf{n}}) Y^*_{\ell' m'}(\hat{\mathbf{n}}'). \tag{2.112}$$

Espectro de Potência das Anisotropias

Assumindo uma isotropia estatística para a radiação da CMB, a função de dois pontos no espaço das funções harmônicas será diagonal e dependerá apenas de ℓ, podendo ser escrita na forma

$$\langle a_{\ell m} a^*_{\ell m} \rangle = C_\ell \delta_{\ell \ell'} \delta_{m m'}, \tag{2.113}$$

onde $C_\ell = \langle |a_{\ell m}|^2 \rangle$ é o espectro angular de potências das anisotropias da CMB.

Dessa forma, o coeficiente de correlação poderá ser escrito como

$$C(\theta) = \sum_{\ell=0}^{\infty} C_\ell \sum_{m=-\ell}^{\ell} Y_{\ell m}(\hat{\mathbf{n}}) Y^*_{\ell' m'}(\hat{\mathbf{n}}') \tag{2.114}$$

ou ainda,

$$C(\theta) = \sum_{\ell=0}^{\infty} \frac{2l+1}{4\pi} C_\ell P_\ell(\cos\theta), \tag{2.115}$$

onde $P_\ell(\cos\theta)$ são os polinômios de Legendre. Esses polinômios são ortogonais no intervalo $[-1,1]$, isto é,

$$\int_{-1}^{1} d\cos\theta P_\ell(\cos\theta) P_{\ell'}(\cos\theta) = \frac{2}{2\ell+1}\delta_{\ell\ell'}, \tag{2.116}$$

portanto, a equação 2.115 pode ser reescrita como

$$C_\ell = 2\pi \int_{-1}^{1} C(\theta) P_\ell(\cos\theta) d\cos\theta. \tag{2.117}$$

Esse resultado estabelece uma relação entre as variações de temperatura no espaço real [xv] e no espaço harmônico.

É possível ainda definir um auto-espectro,

$$D_\ell = \frac{\ell(\ell+1)}{2\pi} C_\ell T_0^2, \tag{2.118}$$

que indica a contribuição aproximada por intervalo logarítmico dos multipolos centrados em ℓ para a variância da flutuação[xvi] (Colaboração Planck, 2020c [13]). Para um universo invariante em escala, D_ℓ seria independente de ℓ.

2.1.5 Espectro de Potências da Matéria

Apesar do Universo ser homogêneo em largas escalas, a presença de estruturas é identificada por *surveys* que mapeiem a distribuição espacial de galáxias, como o SDSS e o 2dF, cujo mapa gerado em seu *Data Release* final pode ser visto na figura 2.4.

Desta forma, é interessante introduzir um campo de perturbações de densidade para um tempo t

$$\delta(\mathbf{x},t) = \frac{\rho(\mathbf{x},t) - \langle\rho\rangle(t)}{\langle\rho\rangle(t)}. \tag{2.119}$$

Este campo pode ser descrito no espaço das funções de Fourier, onde

$$\delta(\mathbf{x},t) = \int \frac{d^3\mathbf{k}}{(2\pi)^3} \delta(\mathbf{k},t) e^{i\mathbf{k}\cdot\mathbf{x}} \tag{2.120}$$

e

$$\delta(\mathbf{k},t) = \int d^3x \delta(x,t) e^{-i\mathbf{k}\cdot\mathbf{x}}. \tag{2.121}$$

[xv] Na verdade, na projeção em duas dimensões deste espaço.
[xvi] Isto é, a função de correlação de dois pontos em $\theta = 0$, $C(0)$.

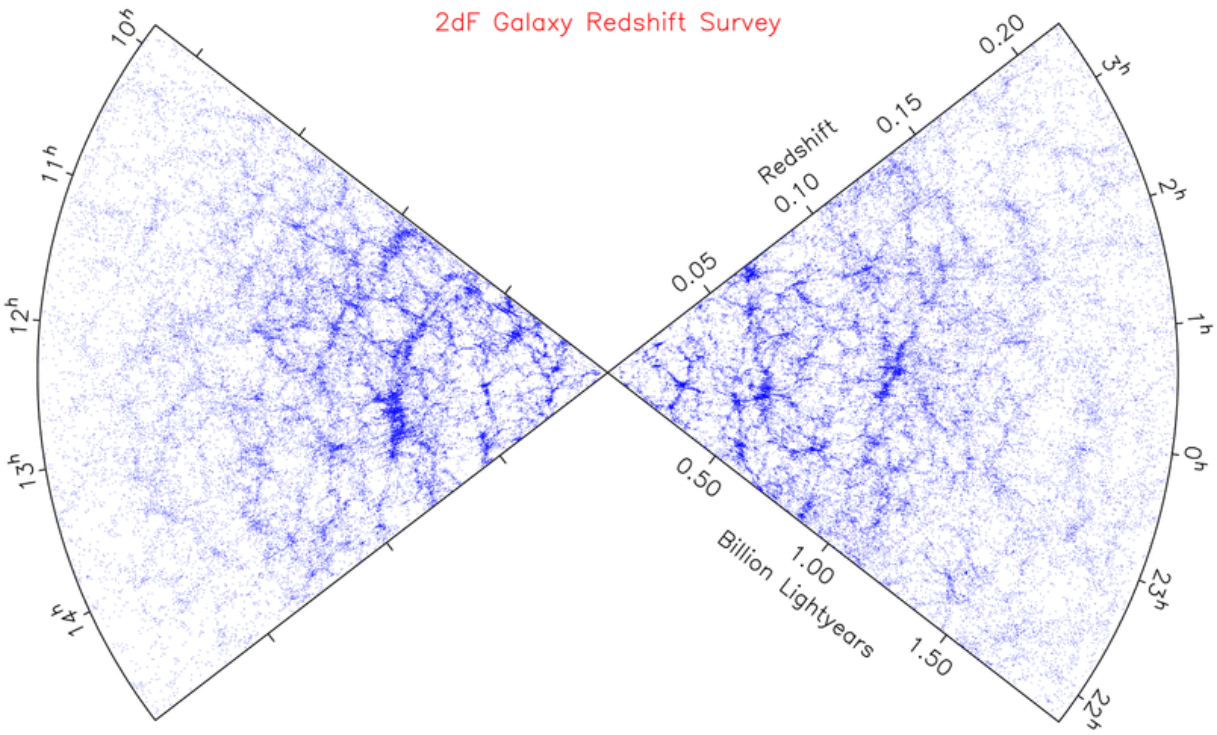

Figura 2.4: Mapa de distribuições das galáxias em função do redshift e da Ascensão Reta obtido pelo *2dF Galaxy Redshift Survey*. Retirado de Colless *et al.*, 2003 [3].

Dado que o campo $\delta(x,t)$ é real, então $\delta^*(\mathbf{k},t) = -\delta(\mathbf{k},t)$. Além disso, também é possível definir funções de correlação neste caso. A função de correlação no espaço de Fourier é

$$\langle \delta(\mathbf{k},t)\delta^*(\mathbf{k}',t)\rangle = (2\pi)^3 \delta_D(\mathbf{k}-\mathbf{k}')P(k,t), \tag{2.122}$$

onde $\delta_D(\mathbf{k}-\mathbf{k}')$ é a delta de Dirac e $P(k,t)$ é o espectro de potências da matéria.

É possível também definir um espectro de potências adimensional $\Delta^2(k,t)$ tal que

$$\Delta^2(k,t) \equiv \frac{k^3}{2\pi^2} P(k,t). \tag{2.123}$$

2.1.6 Espectro de Potências das Flutuações Iniciais de Curvatura

As perturbações em densidade apresentadas na seção anterior são geradas por um campo de perturbações iniciais na curvatura do Universo pós-inflação $R(\mathbf{x},t)$, que também pode ser descrito no espaço de Fourier, de maneira análoga ao feito para o espectro da matéria. Assim, sua função de correlação no espaço de Fourier é dada por

$$\langle R(\mathbf{k},t)R^*(\mathbf{k}',t)\rangle = (2\pi)^3 \delta_D(\mathbf{k}-\mathbf{k}')P_R(k,t) \tag{2.124}$$

e assim como o espectro da matéria, pode se definir um espectro adimensional Δ_R^2.

O espectro de potências adimensional primordial das perturbações de curvatura pode ser escrito na forma de uma lei de potência:

$$\Delta_R^2(k,t_i) = A_s \left(\frac{k}{k_0}\right)^{n_s-1}, \tag{2.125}$$

em que k_0 é uma escala de referência, $A_s = \Delta_R^2(k_0,t_i)$ é a amplitude das variações do espectro de potências primordial e n_s é o índice espectral. Caso $n_s = 1$, as condições iniciais são invariantes de escala.

É possível definir uma função de transferência $\Theta_\ell(k)$ que relacione as condições iniciais do espectro de potências adimensional da curvatura ($\Delta_R^2(k)$) ao espectro de potências da CMB (C_ℓ), considerando a evolução das flutuações de curvatura até o momento pós-desacoplamento. Assim, esses espectros de potência relacionam-se através de [xvii]:

$$C_\ell = 4\pi \int \Theta_\ell^2(k)\Delta_R^2(k)\mathrm{d}\ln k. \tag{2.126}$$

Além da dependência dos parâmetros A_s e n_s, que fica evidente ao se analisar a equação 2.125, a forma final de C_ℓ dependerá também dos parâmetros de composição do Universo, como Ω_b, Ω_m, Ω_k, Ω_Λ e de H_0[xviii], através da função de transferência. Uma derivação analítica deste espectro é feita em Mukhanov (2004) [28].

2.1.7 Influência dos Parâmetros Cosmológicos no Espectro de Potência

A forma do espectro de potências da radiação carrega informações sobre a composição, evolução e estado atual do Universo, podendo ser usada para restringir os valores atuais dos parâmetros cosmológicos. A seguir, serão abordadas a influência de alguns parâmetros de interesse nesse espectro.

Os parâmetros $\Omega_m h^2$ e $\Omega_b h^2$ trazem informações sobre a posição e altura dos picos. Nos gráficos da esquerda da figura 2.5, verifica-se valores mais altos de $\Omega_m h^2$ nos primeiros e segundos picos menores e deslocamentos os picos seguintes para valores de ℓs menores. Já para $\Omega_b h^2$, o efeito de deslocamento é oposto e mais discreto e, enquanto a altura do primeiro cresce com o aumento de $\Omega_b h^2$, a altura do segundo decresce, como pode ser visto nos gráficos da esquerda da figura 2.6.

Além disso, os gráficos da figura 2.5 mostram efeitos bastante semelhantes, principalmente nas escalas maiores. Comparando-os, é possível entender a contribuição de cada termo

[xvii] Mais detalhes podem ser conferidos em Baumann (2022) [1], Dodelson (2003) [26] ou Liddle e Lyth (2000) [27].
[xviii] Note que, fixando-se o valor de Ω_r através das observações da temperatura da CMB e assumindo-se um universo plano, é possível reduzir a quantidade de parâmetros necessários a três.

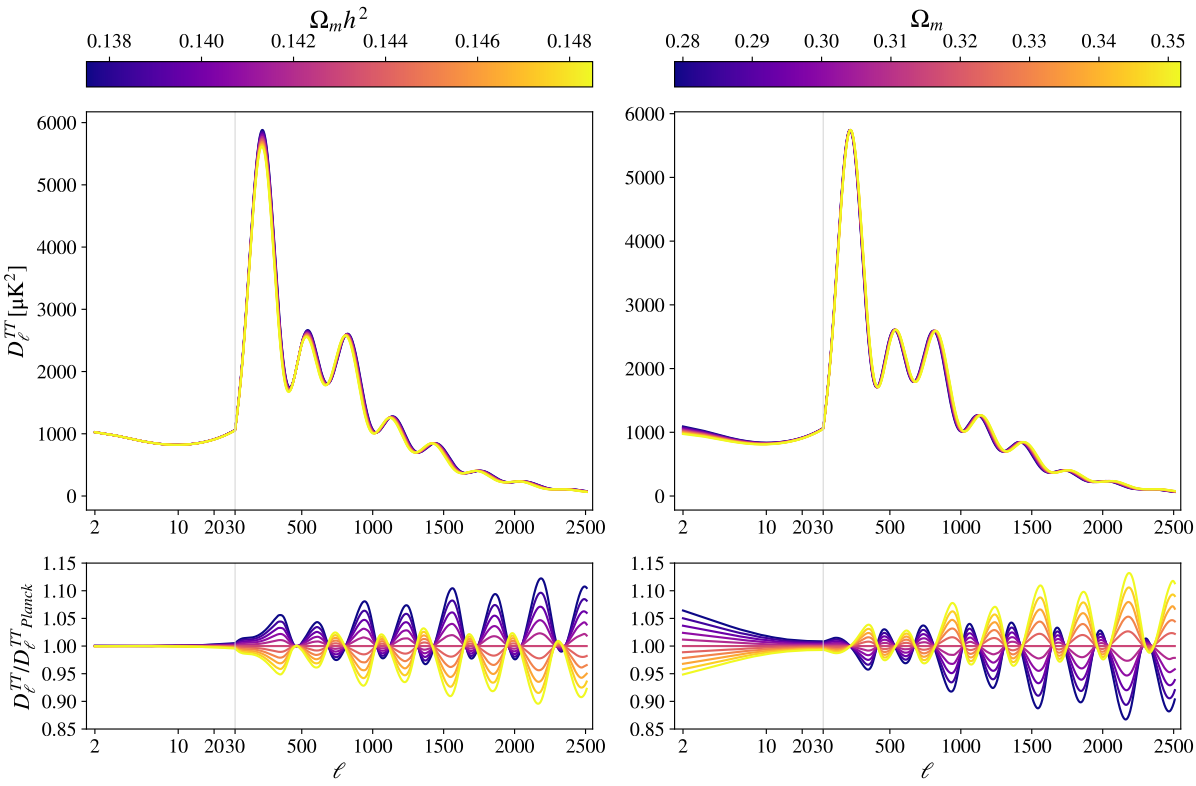

Figura 2.5: Influência dos parâmetros $\Omega_m h^2$ e Ω_m na forma do espectro de potências da CMB. Os gráficos da linha inferior apresentam o valor relativo dos espectros em relação aos valores do espectro traçado a partir dos parâmetros obtidos pela colaboração Planck (2020a) [4].

para $\Omega_m h^2$. Os gráficos à esquerda apresentam a variação de $\Omega_m h^2$ mantendo Ω_m fixo, o que significa uma mudança dos valores devida apenas a alteração em h; já nos gráficos à direita, $\Omega_m h^2$ foi mantido fixo enquanto Ω_m e h foram variados proporcionalmente. Assim, é possível perceber que, além do efeito de deslocamento presente em ambos os gráficos – provavelmente devido a h –, a modificação de Ω_m gera uma alteração nas potências correspondentes a $\ell \lesssim 30$, além de fixar a altura do primeiro e segundo picos.

O parâmetro $10^9 A_s$, apresentado do lado direito da figura 2.6, está relacionado ao espectro das perturbações iniciais da curvatura e, conforme esperado a partir da equação 2.126, seu efeito é exercido sobre a amplitude das variações de temperatura como um todo. Mantendo-se os demais parâmetros constantes, é esperado que A_s seja uma constante multiplicativa em C_ℓ.

O parâmetro n_s, cujo efeito no espectro de potências da radiação é apresentado no lado esquerdo da figura 2.7, também relaciona-se com o espectro de perturbações primordiais da matéria, porém seu efeito no espectro de temperaturas da CMB é mais complicado, uma vez que C_ℓ depende de uma integral em k. Quando analisada a variação relativa dos espectros em relação ao valor obtido pela colaboração Planck (2020a) [4], verifica-se que o principal efeito de sua variação se dá nos momentos de multipolo iniciais ($\ell < 30$), diminuindo gradualmente até $\ell \sim 500$ e voltando a aumentar, porém mais timidamente.

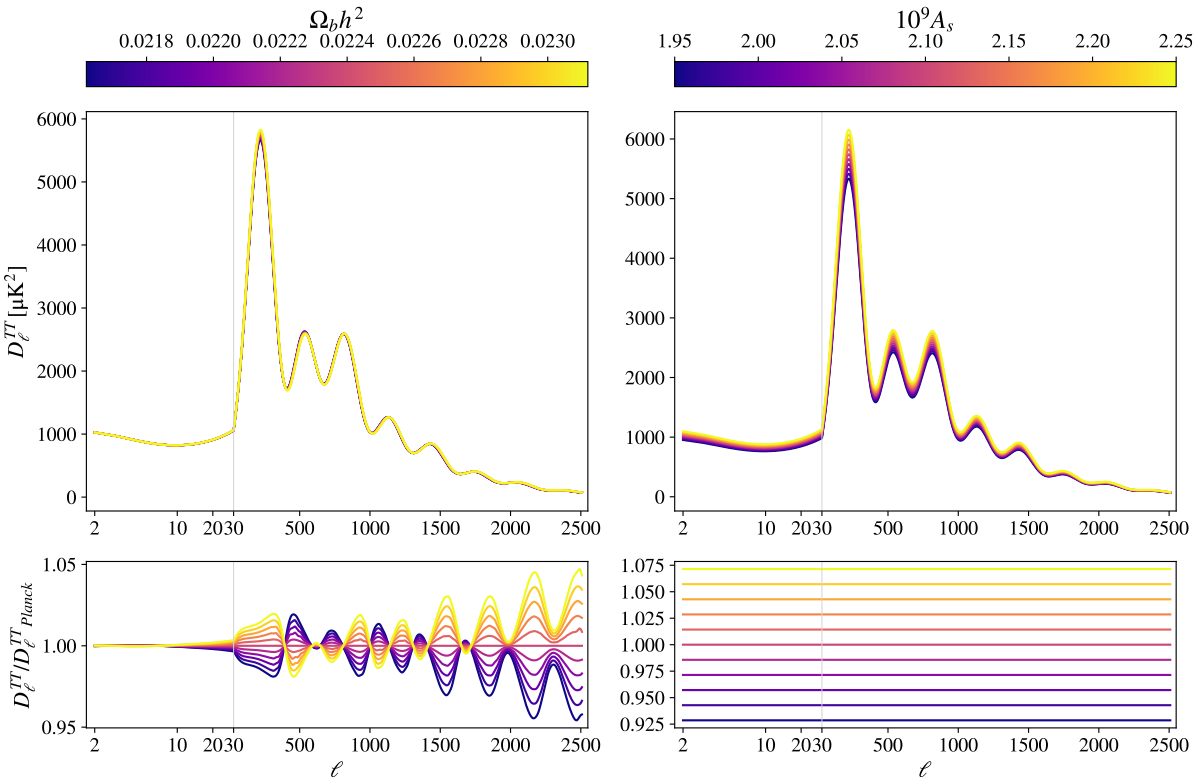

Figura 2.6: Influência dos parâmetros $\Omega_b h^2$ e $10^9 A_s$ na forma do espectro de potências da CMB. Os gráficos da linha inferior apresentam o valor relativo dos espectros em relação aos valores do espectro traçado a partir dos parâmetros obtidos pela colaboração Planck (2020a) [4].

Por fim, o gráfico da direita da figura 2.7 apresenta a influência de τ_{reio} no espectro de potências. Como esse parâmetro interfere no espectro através da absorção dos fótons da CMB, sua variação gera uma alteração aparentemente uniforme em escalas menores (ℓ maiores) que o tamanho do horizonte do Universo durante a reionização. Isso pode fazer com que essa variação seja erroneamente interpretada como causada por A_s. É dito então que há uma degenerescência entre esses parâmetros, que pode ser quebrada por meio da análise dos momentos de multipolo iniciais.

2.2 Códigos de Boltzmann

Para computar a função de transferência mencionada ao fim da seção 2.1.6 de maneira acurada, é necessário resolver um conjunto de equações acopladas que descrevam a evolução dos potenciais das componentes do Universo. Este conjunto é formado pelas equações de Einstein [xix] e pelas equações de Boltzmann.

Essas equações são resolvidas numericamente através dos Códigos de Boltzmann, que utilizam essas equações para computar como se dá a evolução do Universo fora do equilíbrio, oferecendo um conjunto de saídas – por exemplo, os espectros de potências da matéria ou da

[xix] Com a adição de perturbações ao tensor energia-momento.

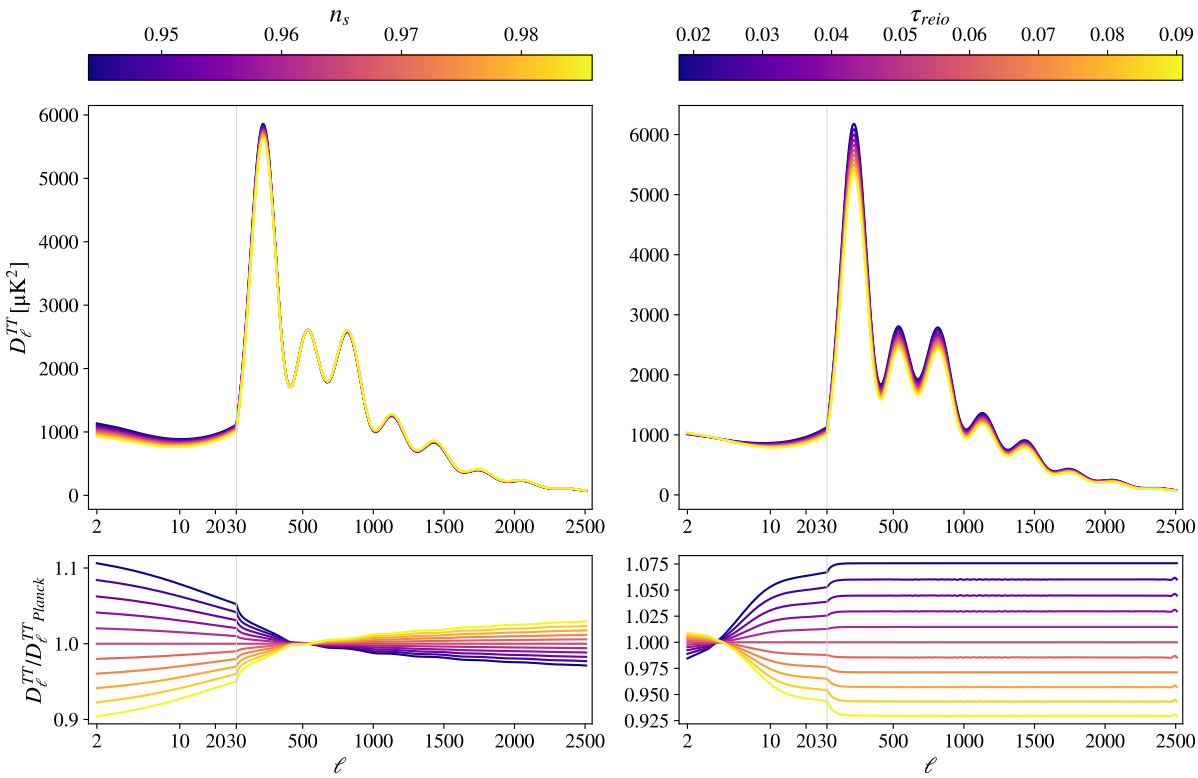

Figura 2.7: Influência dos parâmetros n_s e τ_{reio} na forma do espectro de potências da CMB. Os gráficos da linha inferior apresentam o valor relativo dos espectros em relação aos valores do espectro traçado a partir dos parâmetros obtidos pela colaboração Planck (2020a) [4].

radiação, ou mesmo a própria função de transferência – a partir de um conjunto de parâmetros cosmológicos fornecidos em sua entrada.

Os primeiros códigos de Boltzmann amplamente utilizados, a exemplo do COSMICS (*Cosmological Initial Conditions and Microwave Anisotropy Codes*) [29], faziam a computação das equações diretamente. Com o passar do tempo, códigos mais recentes, como o CMBFAST [30], o CAMB (*Code for Anisotropies in the Microwave Background*) [31] e o CLASS (*Cosmic Linear Anisotropy Solving System*) [32], lançaram mão de aproximações numéricas para reduzir o custo em tempo computacional.

Apesar dos códigos atuais terem sido capazes de reduzir seu tempo de computação, novas maneiras de diminuir esse tempo permanecem como um tema de interesse para a cosmologia moderna, visto que um dos principais usos dos códigos de Boltzmann é feito por algoritmos – códigos de Monte Carlo – que executam-os diversas vezes para restrição de valores dos parâmetros cosmológicos.

2.3 Aprendizado de Máquina

O Aprendizado de Máquina – em inglês, *Machine Learning* (ML) – é um termo usado para denominar a ciência de programar computadores para que eles sejam capazes de aprender a partir dos dados (Géron, 2019 [33]). O ML é um tipo de Inteligência Artificial (IA), que por sua vez constitui-se como o esforço para automatizar tarefas intelectuais geralmente performadas por seres humanos (Chollet, 2021 [34]) e engloba tarefas muito mais amplas, em que não necessariamente há um aprendizado envolvido.

Para que um algoritmo de ML aprenda, geralmente são fornecidas entradas, também chamadas de *features*, e saídas, também chamadas de *targets*. As *features* são propriedades conhecidas dos dados, que podem ser mensuradas, observadas ou simuladas (Acquaviva, 2023 [35]). Já os *targets* são aquelas propriedades sobre as quais se deseja conhecer melhor ou ser capaz de realizar predições.

O conjunto de dados fornecidos para que o algoritmo aprenda geralmente é chamado de conjunto de treino. Além desse conjunto, geralmente são separados dados distintos para a realização do teste do algoritmo, a fim de avaliar o grau de sucesso de suas predições em dados desconhecidos pelo algoritmo. Há ainda a possibilidade de se dispor de um conjunto de validação, que é usado para a escolha do melhor conjunto de parâmetros para o treino.

2.3.1 Tipos de Aprendizado

Visto que o aprendizado é uma característica importante do ML, diversos processos – algoritmos ou modelos – foram criados para que ele ocorra a partir dos dados. Consequentemente, é comum que os algoritmos de ML sejam classificados de acordo com a forma como o aprendizado ocorre. As formas de classificar o Aprendizado de Máquina podem se basear em características diversas, a exemplo:

- Se o treino requer ou não o fornecimento de dados de saída classificados;
- A frequência com que o algoritmo é alimentado com novos dados;
- No caso de haverem saídas classificadas, se essas saídas têm uma quantidade discreta ou contínua de possibilidades.

Essas classificações podem se sobrepor e complementar. A seguir, serão abordadas algumas delas.

Aprendizado Supervisionado e Aprendizado Não-Supervisionado

O aprendizado supervisionado se dá quando o algoritmo recebe, além das *features*, *targets* categorizadas, analisando-as a fim de aprender qual seria a saída esperada a partir de um

determinado conjunto de parâmetros. Dois tipos muito comuns de aprendizados supervisionado são a regressão e a classificação.

No aprendizado não-supervisionado, não há o fornecimento de saídas categorizadas durante o treino: o objetivo do modelo é tentar descobrir e prever padrões nos dados. Alguns dos principais algoritmos de aprendizagem não-supervisionada são o *clustering* e a redução de dimensionalidade.

Além dessas categorias, há também o aprendizado semisupervisionado e o *reinforcement learning*. O aprendizado semisupervisionado lida com dados semi-rotulados, por vezes combinando algoritmos supervisionados e não-supervisionados. Já no *reinforcement learning*, o sistema de aprendizagem observa o meio e realiza ações, ganhando recompensas ou penalidades de forma que ele possa desenvolver a melhor estratégia para maximizar o ganho de recompensas (Géron, 2019 [33]).

Aprendizado *Online* e Aprendizado *Offline*

No aprendizado *online*, o algoritmo está constantemente recebendo novos dados para o melhoramento do modelo, permitindo sua incrementação de maneira mais dinâmica. No aprendizado *offline*, também chamado de aprendizado em lotes, o sistema é treinado usando todos os dados disponíveis para isso; a incrementação do modelo só é possível através de um novo processo de treino.

Classificação e Regressão

A classificação e a regressão são dois tipos de aprendizado supervisionado, que diferem-se quanto a natureza dos dados de saída: na classificação, há um conjunto discreto de possibilidades para essas variáveis; já na regressão, os *targets* são variáveis contínuas.

Isso influencia na forma como o sucesso desses modelos é avaliado. Na classificação, geralmente são utilizados métodos que avaliem a proporção de resultados corretamente classificados; já na regressão, as métricas avaliam o quão próximo do valor real encontram-se as predições.

2.3.2 Regressão Simbólica

A Regressão Simbólica – em inglês, *Symbolic Regression* (SR) – é um algoritmo de aprendizado de máquina que performa a automatização do processo que historicamente era feito por cientistas de maneira manual: a busca por expressões empíricas que fossem simples e acuradas através de uma combinação de intuição e tentativa e erro (Cranmer, 2023 [6]).

A SR baseia-se na tentativa de descrição funcional da relação entre as entradas e saídas por meio da exploração de um espaço de operadores e funções matemáticas, permitindo não só

o ajuste aos dados, mas também a interpretabilidade e simplicidade das equações geradas. Isso a diferencia dos outros tipos de regressão pois, ao invés de partir de uma forma pré-definida de expressão – como é o caso das regressões linear e logística –, ela combina diversas possibilidades de expressão em busca da que melhor descreva o fenômeno investigado.

Programação Genética

Existem diversos métodos para a execução da regressão simbólica, sendo a Programação Genética um dos mais populares. Baseada nos princípios de evolução biológica, ela segue um princípio que assemelha-se à seleção natural, onde populações formadas por "árvores de expressões" – em inglês, *expression trees* – evoluem, sofrem mutações [xx] e se combinam [xxi] ao longo das iterações, de forma que as árvores que melhor se adaptem, isto é, que melhor se ajustem aos dados, prevaleçam. Um exemplo de *expression tree* pode ser conferido na figura 2.8.

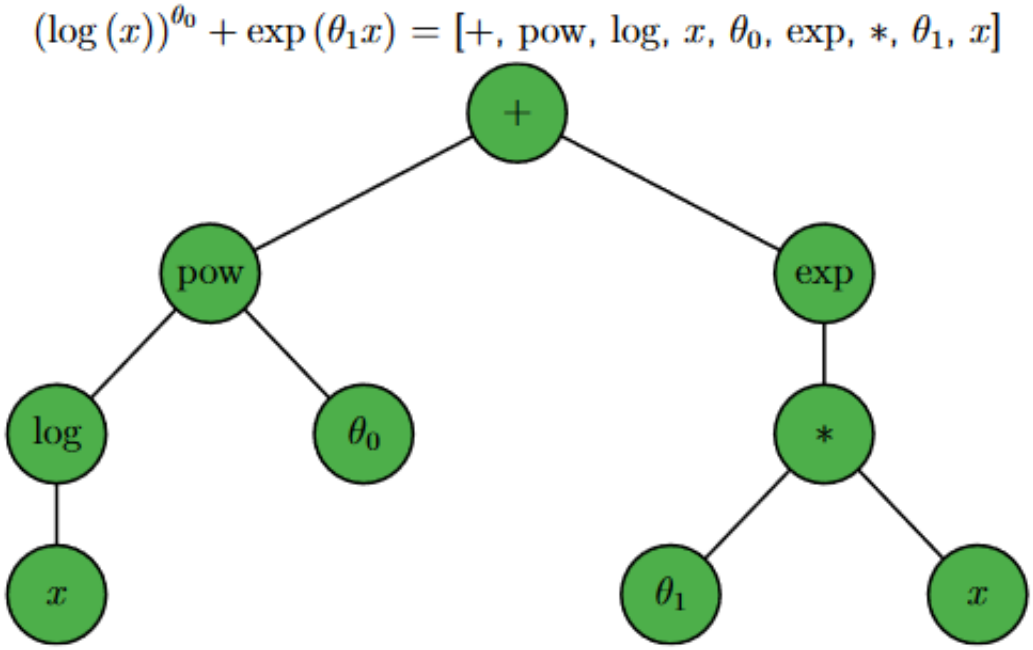

Figura 2.8: *Expression tree* representativa da função $(\log(x))^{\theta_0} + \exp(\theta_1 x)$. Retirado de Bartlett *et al.*, 2023 [5].

2.3.3 Underfitting e Overfitting

Um dupla de conceitos importantes em Aprendizado de Máquina, principalmente em algoritmos de regressão, são o *underfitting* e o *overfitting*. No *underfitting*, também chamado de subajuste, o modelo é simples demais para que os dados sejam corretamente apreendidos, causando uma má performance tanto durante o treino, quanto durante o teste. Já no *overfitting*

[xx] Processo no qual há a troca aleatória de uma das expressões.
[xxi] Através de um processo chamado de *crossover*

ou sobreajuste, há uma adaptação excessiva aos dados de treino, que faz com que o modelo perca sua generalidade, performando bem durante o treino, mas não sendo capaz de descrever bem o conjunto de dados de teste.

Capítulo

3

Metodologia

"I have a great supervised machine learning joke...
But you need to have heard a similar one before."

(***Viviana Acquaviva***)

3.1 Definição do Método e Preparação dos Dados

3.1.1 Escolha das *Features*

Para a elaboração do modelo, foram escolhidos como *features* 6 parâmetros cosmológicos a serem variados: $\Omega_m h^2$, Ω_m, $\Omega_b h^2$, $10^9 A_s$, n_s e τ_{reio}. Esses parâmetros são utilizados por Mukhanov (2004) [28] em sua derivação analítica para as flutuações do espectro da Radiação Cósmica de Fundo e por isso foram considerados promissores como variáveis de entrada para este modelo.

Os três primeiros parâmetros utilizados estão relacionados à composição do Universo em densidade de matéria – que corresponde à soma entre as densidades em matéria bariônica e em matéria escura, conforme visto na equação 2.69 – e em densidade de energia escura, a partir da componente $\Omega_\Lambda \simeq 1 - \Omega_m$ [i]. Também é possível obter a partir deles a taxa de expansão atual do universo, $H_0 = 100h$. Os parâmetros n_s e $10^9 A_s$ relacionam-se com o espectro de potência das perturbações de curvatura primordiais, sendo importantes para o entendimento do processo de formação de estruturas no Universo. Por fim, o parâmetro τ_{reio} traz informações sobre como a matéria bariônica no Universo pós-reionização impacta na absorção dos fótons da CMB. Juntos, esses parâmetros fornecem os ingredientes necessários para traçar como a estrutura e evolução do Universo em diferentes momentos influencia a distribuição estatística de temperaturas dos fótons que compõem a Radiação Cósmica de Fundo.

Além disso, como a variação dos valores do espectro de potências da CMB também depende do momento de multipolo ℓ, influenciando nos dados de saída, foi preciso inclui-lo nas *features*, de forma que o número de dados utilizados em cada etapa correspondeu a $n_{tot} = n_{sets} \cdot n_{\ell_b}$, onde n_{sets} é o número de conjunto de parâmetros e n_{ℓ_b} é a quantidade de ℓ_b utilizados[ii].

[i] Pois o valor da componente Ω_r, possível de ser estimado a partir da distribuição de temperaturas dos fótons da Radiação Cósmica de Fundo, é $\Omega_r = 9 \cdot 10^{-5} \ll 1$ e, segundo os dados da missão Planck (2020a) [4], $\Omega_k = 0,001 \pm 0,002$, o que é baixo o bastante para tornar a aproximação apresentada válida.

[ii] essas informações serão abordadas com mais detalhes nas seções 3.1.2 e 3.1.4, que tratam da quantidade de

3.1.2 Variação dos Parâmetros de Entrada

Para o treino do modelo, foram utilizados 100 conjuntos de parâmetros cosmológicos que correspondiam a variações dos parâmetros escolhidos dentro do intervalo de $\pm 5\sigma$ dos valores encontrados pela colaboração Planck (2020a) [4]. Outros 100 conjuntos de parâmetros foram utilizados durante a validação. Por fim, para o teste do modelo, foram gerados mais 100 conjuntos de parâmetros com variações dentro de $\pm 1\sigma$ e $\pm 2\sigma$. Os valores e incertezas utilizados como referência encontram-se disponíveis na tabela 3.1.

Parâmetro	Valor $\pm 1\sigma$
$\Omega_m h^2$	$0,1430 \pm 0,0011$
Ω_m	$0,3153 \pm 0,0073$
$\Omega_b h^2$	$0,02237 \pm 0,00015$
$10^9 A_s$	$2,100 \pm 0,030$
n_s	$0,9649 \pm 0,0042$
τ_{reio}	$0,0544 \pm 0,0073$

Tabela 3.1: Valores e incertezas encontrados pela colaboração Planck (2020a) [4] para os parâmetros cosmológicos selecionados.

Latin Hypercube (LH)

De forma a manter a uniformidade da distribuição dos parâmetros, foi feita a confecção de um *Latin hypercube* (LH), que consiste na seleção de pontos feita a partir da divisão de cada dimensão do espaço de parâmetros em N intervalos de igual probabilidade $1/N$, onde N é o número de pontos que se deseja obter. Os pontos são selecionados de forma a garantir que ao final cada dimensão contenha um distribuição aproximadamente plana de pontos.Mais detalhes podem ser obtidos em McKay *et al.* (1979) [36].

O efeito prático do *latin hypercube* pode ser visualizado ao se comparar as figuras 3.1 e 3.2: é visível que, para um número de dados reduzido, o *latin hypercube* permite uma distribuição equiprovável de variáveis que não seria possível apenas tomando valores aleatórios dentro de um intervalo.

3.1.3 Obtenção dos Dados de Saída

Conforme discutido na seção 2.3.2, a regressão simbólica se caracteriza como um método de aprendizado supervisionado e por isso, além do fornecimento dos dados de entrada, é necessário também fornecer dados de saída para que o algoritmo aprenda qual o resultado esperado a partir de um determinado *input*.

sets e da binagem dos dados de saída que gerou os ℓ_b, respectivamente.

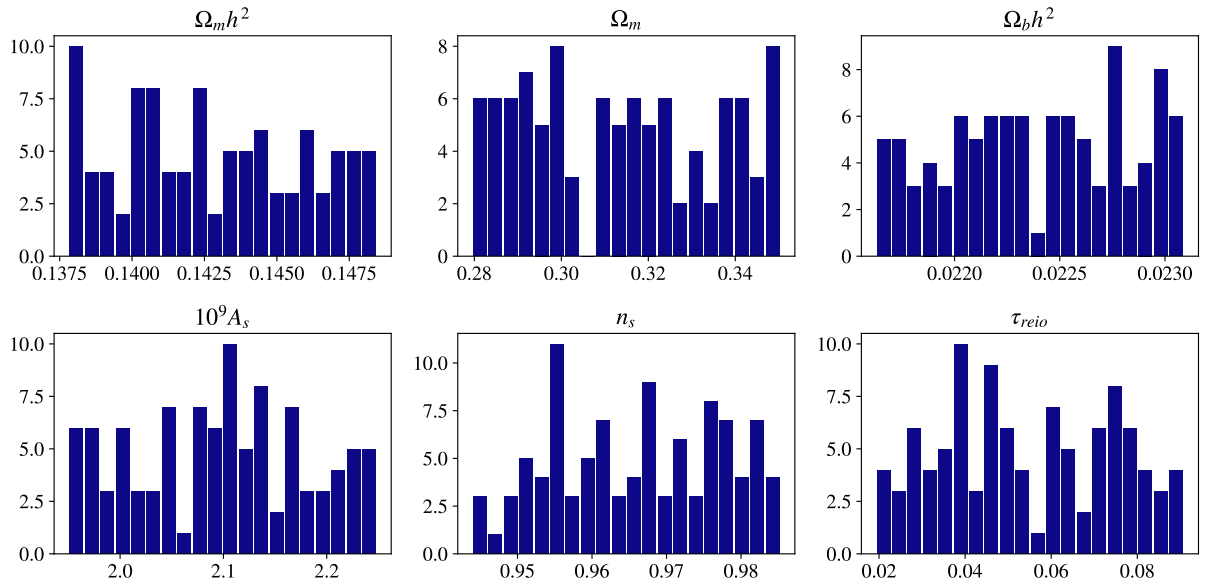

Figura 3.1: Distribuição do conjunto de parâmetros para 100 amostras com a variação aleatória dos valores dentro do intervalo de $\pm 5\sigma$ obtidos pela colaboração Planck (2020a) [4].

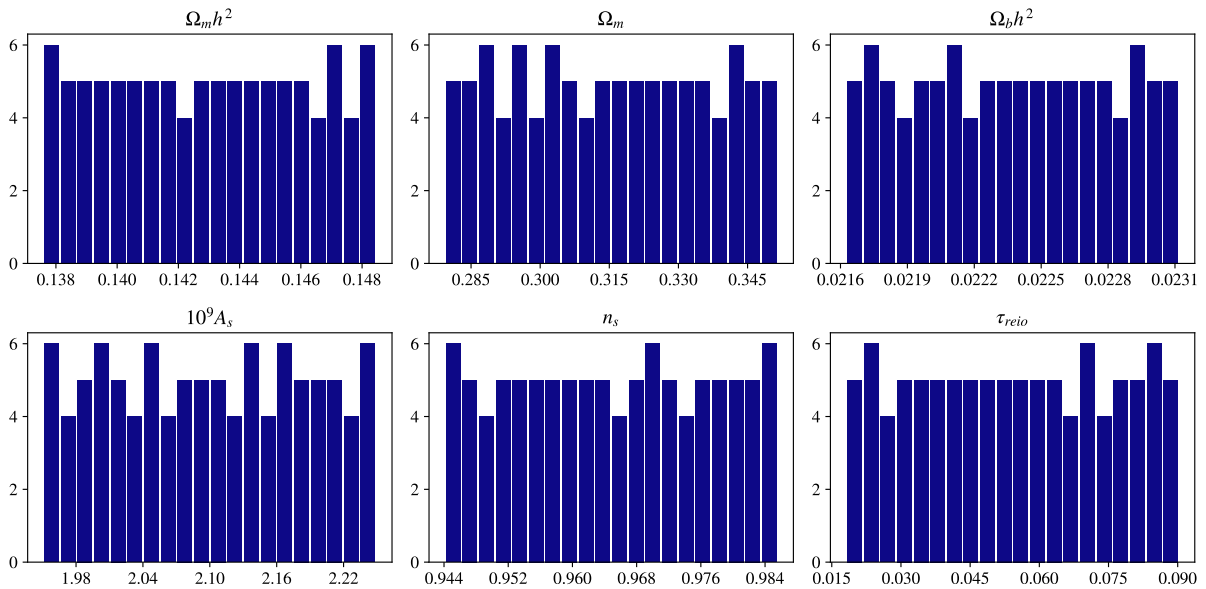

Figura 3.2: Distribuição do conjunto de parâmetros dos dados de treino.

CLASS

Para a obtenção dos dados de saída utilizados neste trabalho, foi escolhido o CLASS (*Cosmic Linear Anisotropy Solving System*), um dos mais populares códigos de Boltzmann da atualidade, desenvolvido por Blas, Lesgourgues e Tram em 2011 [32]. Sua escolha se deve não somente à sua rapidez quando comparado a outros códigos, mas também ao seu bom atendimento aos objetivos de flexibilidade, usabilidade e exatidão estabelecidos em sua criação (Lesgourgues, 2011 [37]), além da possibilidade de integração com o MontePython [38], um pacote para a inferência de parâmetros em cosmologia. O CLASS também dispõe de *wrappers* em Python e C++, permitindo o desenvolvimento de *scripts* em Python para realização de diversas

computações de maneira automatizada, utilizados durante o desenvolvimento deste trabalho.

Para a execução dos *scripts*, foi necessário o fornecimento de um conjunto de parâmetros cosmológicos fixos – além dos parâmetros variáveis já mencionados – a serem utilizados em cada computação. Os parâmetros fixos (tabela A.1) e os valores máximos e mínimos de cada parâmetro variado (tabela A.2) durante as computações encontram-se disponíveis no apêndice A. A partir desses parâmetros, foi possível obter os C_ℓ^{TT} correspondentes a cada *input*.

Uma análise visual do comportamento desses dados ressalta a importância do treino com a variação de diferentes parâmetros cosmológicos simultaneamente: ao se dispor a variação de cada parâmetro escolhido para os espectros correspondentes a dez dos conjuntos de entrada gerados, vê-se que, uma vez que mais de um parâmetro é variado ao mesmo tempo, a alteração no espectro deixa de seguir um padrão claro, devido à presença de degenerescências entre os efeitos causados por cada parâmetro. Isso é bem diferente do observado para os gráficos em que há a variação de apenas um parâmetro, apresentados na parte inferior das figuras 2.5 a 2.7.

3.1.4 Tratamento dos Dados

Uma vez em posse dos dados de entrada e saída, fez-se necessário ainda o tratamento dos dados para a melhor performance do algoritmo de regressão.

Binagem

De forma a otimizar o tempo de treino dos modelos, foi feita a binagem dos dados de saída de acordo com o artigo V dos resultados publicados em 2018 pela colaboração Planck (2020b) [7], totalizando 243 valores de C_ℓ^{TT} binados, denotados por C_b, onde b corresponde ao número do *bin*. As larguras dos *bins* para cada intervalo encontram-se na tabela 3.2.

Intervalo	Largura dos *bins* ($\Delta\ell$)
$2 \leq \ell \leq 29$	1
$30 \leq \ell \leq 99$	5
$100 \leq \ell \leq 1503$	9
$1504 \leq \ell \leq 2013$	17
$2014 \leq \ell \leq 2508$	33

Tabela 3.2: Larguras de *bin* usadas dentro de cada intervalo de ℓs. Os valores apresentados foram obtidos no artigo V da colaboração Planck (2020b) [7].

Para a binagem, os valores dos C_ℓ^{TT} foram ponderados de acordo com a equação:

$$C_b = \sum_{\ell=\ell_b^{min}}^{\ell_b^{max}} w_b^\ell C_\ell^{TT}, \qquad w_b^\ell = \frac{\ell(\ell+1)}{\sum_{\ell=\ell_b^{min}}^{\ell_b^{max}} \ell(\ell+1)}. \tag{3.1}$$

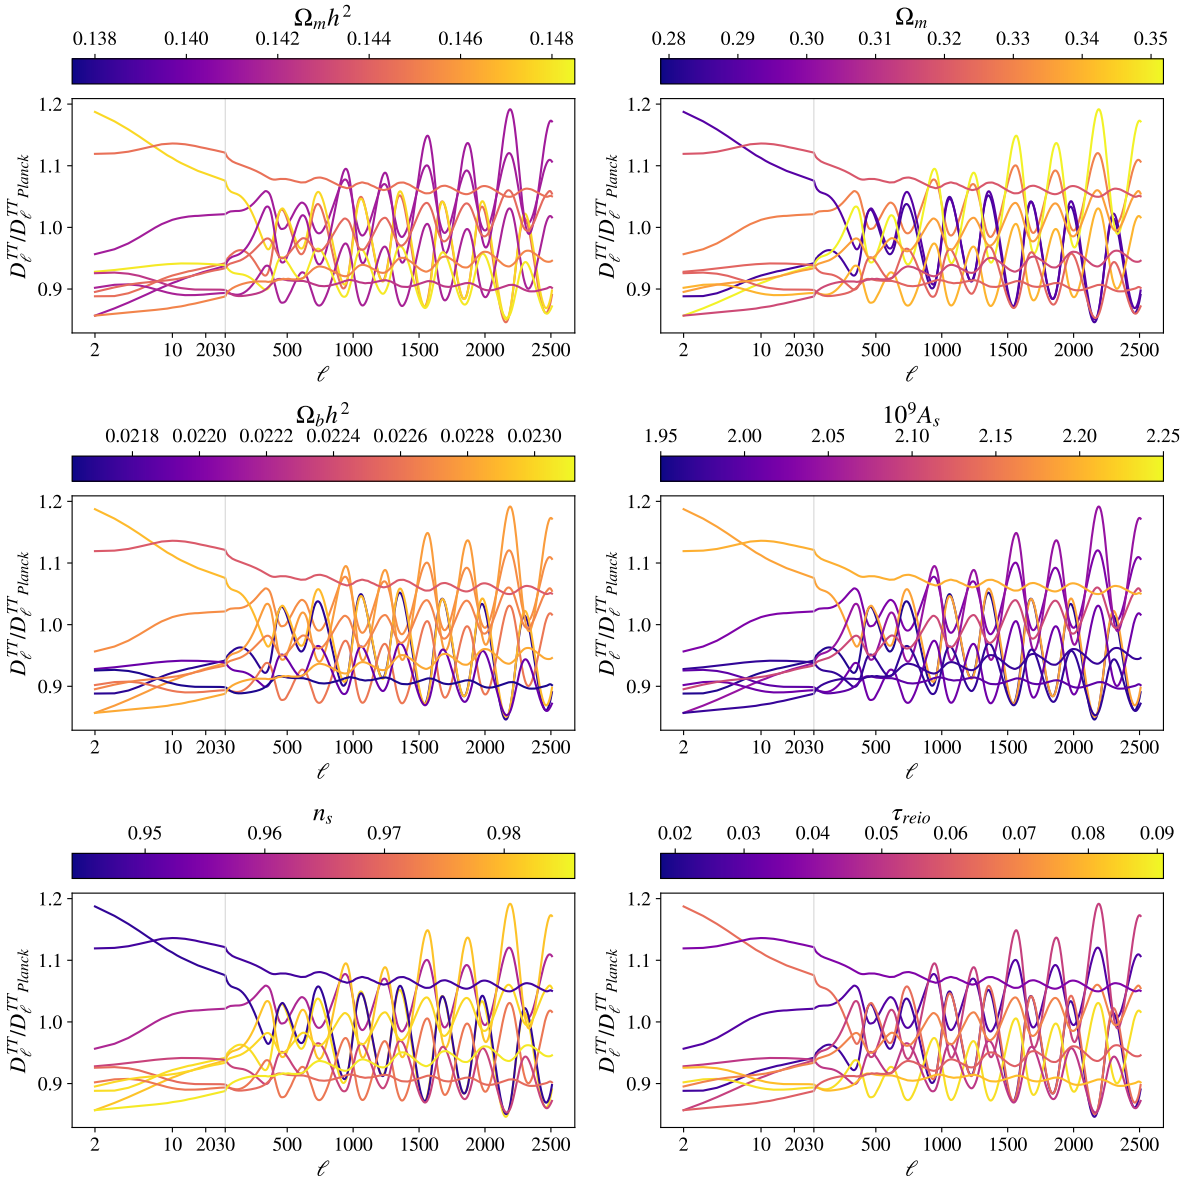

Figura 3.3: Distribuição dos valores dos parâmetros $\Omega_m h^2$, Ω_m, $\Omega_b h^2$, $10^9 A_s$, n_s e τ_{reio} para 10 dos espectros utilizados durante o treino. Nestes gráficos, a fim de permitir a melhor visualização e comparação com os gráficos da parte inferior das figuras 2.5 a 2.7, os valores dos D_ℓ^{TT} de cada espectro foram divididos pelo valor computado a partir dos valores obtidos pela colaboração Planck (2020a) [4].

Os valores efetivos dos ℓ para cada C_b, ℓ_b, por sua vez foram encontrados a partir da média ponderada dos ℓ para cada intervalo binado:

$$\ell_b = \frac{\sum_{\ell=\ell_b^{min}}^{\ell_b^{max}} w_b^\ell \ell}{\sum_{\ell=\ell_b^{min}}^{\ell_b^{max}} w_b^\ell} = \frac{\sum_{\ell=\ell_b^{min}}^{\ell_b^{max}} \ell^2 (\ell+1)}{\sum_{\ell=\ell_b^{min}}^{\ell_b^{max}} \ell (\ell+1)}. \tag{3.2}$$

Transformação dos Dados

Após a binagem, foi realizada a transformação dos dados de saída, reescrevendo-os em termos do auto-espectro

$$D_b = \frac{\ell_b(\ell_b+1)}{2\pi} C_b \cdot \left(2,73 \cdot 10^6 \mu K\right)^2, \tag{3.3}$$

de forma que os valores dos espectros fossem dispostos na forma classicamente apresentada em gráficos como os das figuras 2.5 a 2.7.

Em seguida, foram realizados quatro procedimentos diferentes, a fim de avaliar qual teria mais sucesso na etapa de validação:

- normalização (N);
- aplicação de escala logarítmica seguida de normalização (Nlog);
- standardização (S); e
- aplicação de escala logarítmica seguida de standardização (Slog).

Normalização

Nos modelos N e Nlog foi feita a normalização das saídas, que consiste na aplicação da operação

$$D_b^{transf} = \frac{D_b - D_{min}}{D_{max} - D_{min}}, \tag{3.4}$$

de forma que valores dos D_b^{transf} variem entre 0 e 1. Os valores mínimo e máximo de D_b para o caso em que foi aplicada apenas a normalização encontram-se disponíveis na tabela 3.3.

D_{min}	$58,0907$
D_{max}	$6657,63$

Tabela 3.3: Valores máximo e mínimo dos D_b dos espectros obtidos para os dados do treino em que foi feita apenas a normalização.

Standardização

Para os modelos S e Slog, foi aplicada a standardização, que consiste em fazer a transformação

$$D_b^{transf} = \frac{D_b - D_\mu}{D_\sigma}, \tag{3.5}$$

onde D_μ é o valor médio das saídas e D_σ é seu desvio-padrão, de forma que a distribuição das saídas transformadas tenha média 0 e desvio-padrão 1. Os valores de D_μ e D_σ para o caso em que foi aplicada apenas a standardização encontram-se disponíveis na tabela 3.4.

D_μ	$1606,75$
D_σ	$1704043,5$

Tabela 3.4: Média e desvio-Padrão dos D_b dos espectros obtidos para os dados do treino em que foi feita apenas a standardização.

Escala Logarítmica

Nos modelos Nlog e Slog foi aplicada a escala logarítmica antes dos respectivos procedimentos descritos anteriormente. Nas equações 3.4 e 3.5, ao invés de D_b, foi utilizado $D_{b,ln}$, que é dado por

$$D_{b,ln} = \ln(D_b). \tag{3.6}$$

Os valores máximo e mínimo (tabela 3.5) e a média e desvio-padrão (tabela 3.6) desses modelos encontram-se a seguir.

$D_{min}^{(ln)}$	$4,06201$
$D_{max}^{(ln)}$	$8,80352$

Tabela 3.5: Valores máximos e mínimos dos D_b dos espectros obtidos para os dados do treino em que foi feita a aplicação de escala logarítmica seguida por normalização.

$D_\mu^{(ln)}$	$7,02852$
$D_\sigma^{(ln)}$	$0,855190$

Tabela 3.6: Média e desvio-Padrão dos D_b dos espectros obtidos para os dados do treino em que foi aplicada a escala logarítmica seguida pela standardização.

3.2 Execução da Regressão Simbólica

Uma vez dispondo dos dados de entrada e saída, foi possível executar a regressão simbólica. Para isso, escolheu-se o algoritmo PySR.

3.2.1 PySR

O PySR é uma biblioteca *open-source* de regressão simbólica com interface em *Python* e *backend* em Julia. Seu algoritmo é baseado na programação genética, com a implementação de um processo chamado de evolução multi-população, em que há a combinação de um *loop* interno em cada população, no qual ocorre a evolução das árvores de expressão por meio de mutações e *crossovers*; com um *loop* externo, que promove a migração de árvores de uma população, também chamada de ilha, para outra, conforme pode ser visto na figura 3.4.

Essa biblioteca implementa modificações ao algoritmo de programação genética convencional: evolução regularizada por idade, em que a árvore mais antiga é substituída, ao invés

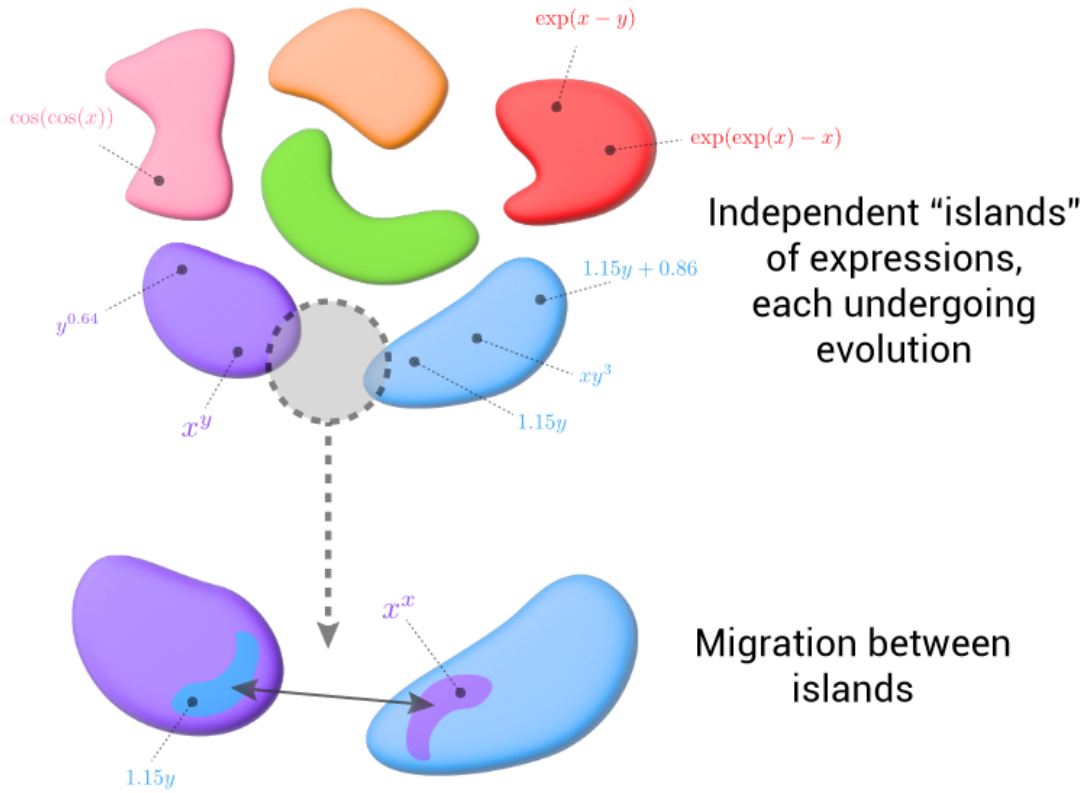

Figura 3.4: Esquematização do processo de *loop* externo do PySR. Retirado de Cranmer (2023) [6].

da com pior *fitting*, de forma a evitar convergências prematuras; processos de simplificação de expressões e otimização de constantes ao fim de um ciclo de evoluções; e uma parcimônia adaptativa, que consiste em um mecanismo de punição da complexidade [iii] que se adapta ao quão frequentemente uma determina complexidade aparece em uma população, o que estimula a exploração tanto de termos simples quanto daqueles mais complexos.

Hiperparâmetros

Outra característica do PySR é sua ampla possibilidade de personalização através dos diversos hiperparâmetros configuráveis. Abaixo, são comentados os conjuntos mais decisivos para essa análise:

- Operadores (`unary_operators` e `binary_operators`): definem as operações unárias e binárias que poderão ser utilizadas nas árvores de expressões. A diferença entre as operações unárias e binárias está na quantidade de nós que elas comportam;
- Restrições (`constraints` e `nested_constraints`): adicionam restrições à complexidade dos termos contidos em um determinado nó.
- Iterações (`niterations` e `ncycles_per_iteration`): definem quantas vezes o pro-

[iii] Definida como o número de elementos, chamados de nós, que compõem a árvore de expressões. Por exemplo, na figura 2.8, cada nó é representado em verde e a expressão possui complexidade 9.

cesso de *looping* acontece e quantas mutações a cada 10 amostras da população por iteração acontecem;

- Populações (`populations`): informa quantas populações devem ser geradas;
- Tamanho Máximo (`maxsize`): define a complexidade máxima que uma árvore de expressões pode ter;
- Otimização (`weight_optimize`, `optimize_probability` e `optimizer_iterations`): controlam a frequência com que as otimizações ocorrem;
- Parcimônia (`parsimony` e `adaptive_parsimony_scaling`): definem um fator inicial para punir a complexidade e o quanto esse fator deve escalar.

A lista contendo todos os hiperparâmetros fornecidos para o treino dos dados encontra-se disponível no apêndice B. Para este trabalho, os operadores escolhidos foram a soma, a multiplicação, o logaritmo natural, o exponencial, o seno e a potenciação. Foram efetuadas 5000 iterações, com 120 populações cujas árvores de expressões tinham complexidade máxima igual a 100.

3.2.2 Escolha da Equação Final

Ao fim da execução, o PySR fornece uma lista de equações que melhor performaram dentro de cada complexidade, além da função de perda – chamada de *loss* pelo algoritmo – e do *score*, métricas que orientam a escolha da equação final dentre as candidatas.

A partir dessas métricas, o PySR define três métodos para a seleção da equação final: "*Accuracy*", que seleciona a equação com menor *loss*, "*Score*", que seleciona a equação com maior *score* e "*Best*", que seleciona a equação com maior *score* dentre aquelas com *loss* menor que $1,5$x o menor valor de *loss*.

Loss (Mean Squared Error)

O PySR permite a definição de uma função de perda a partir da qual a capacidade de ajuste das equações geradas será avaliada. Neste trabalho o Erro Quadrático Médio – *Mean Squared Error*, abreviado como MSE – foi utilizado como função de perda.

Essa métrica baseia-se em avaliar o quanto os dados preditos distanciaram-se dos valores reais – também chamados de fiduciais – através da medida da média dos erros absolutos ao quadrado:

$$\text{MSE} = \frac{\sum_{i=1}^{n_{tot}} (y_i - \hat{y}_i)^2}{n_{tot}}, \tag{3.7}$$

onde y_i e $\hat{y}_i$ são as componentes do vetor formado por todos os valores de D_b e $\hat{D}_b$, respectivamente, e n_{tot} é o número total de dados utilizados.

Score

O *score* dentro do PySR é definido como zero para a primeira equação da lista e como a derivada negativa do logaritmo da *loss* em função da complexidade para os demais itens, ou seja

$$\text{SCORE} = -\frac{\ln L_i - \ln L_{i-1}}{z_i - z_{i-1}}, \tag{3.8}$$

onde L_i denota a função de perda correspondente à equação i da lista e z_i corresponde à complexidade dessa equação.

Método *"Best"*

A escolha da equação final baseada nos métodos "*Accuracy*" e "*Score*" nem sempre se caracteriza como a melhor alternativa: o primeiro método pode conduzir a equações mais complexas que o necessário, causando o *overfitting* dos dados; já o segundo, em modelos com uma quantidade maior de variáveis independentes – como é o caso –, pode conduzir a equações que gerem uma grande melhoria em relação à equação anterior na lista, mas que ainda não capturem completamente o modelo descrito [iv], causando o subajuste dos dados.

Assim, foi utilizado para escolha da equação final o método "*Best*" descrito anteriormente, como uma forma de equilibrar ambos os preceitos, escolhendo-se a equação que gera a melhoria do ajuste mais significativa dentre as mais acuradas.

3.3 Métricas de Performance

Um dos principais mecanismos para avaliar a aplicabilidade de um método é através do uso de métricas de performance. Abaixo, serão apresentadas as métricas utilizadas neste trabalho. Vale salientar que essas análises consideram os dados após a aplicação da transformação inversa, ou seja, são analisados os valores de D_b preditos e fiduciais.

3.3.1 R²

O R^2, também chamado de coeficiente de determinação, descreve o quanto da variabilidade da variável dependente (y) pode ser explicada pelo modelo criado. Ele pode ser descrito como uma função de duas variáveis: a soma dos quadrados totais (SS_{tot}), que consiste na soma dos quadrados das diferenças entre os valores reais e a média desses valores, e a soma dos quadrados dos resíduos (SS_{res}), que trata-se do somatório dos quadrados das diferenças entre os

[iv] Isso pode ser visto na figura 4.2, em que a equação com máximo *score* representa uma perda consideravelmente maior que as demais opções.

valores fiduciais e os preditos através do modelo ($\hat{y}$), ou seja,

$$SS_{tot} = \sum_{i=1}^{n_{tot}} (y_i - \bar{y})^2, \qquad SS_{res} = \sum_{i=1}^{n_{tot}} (y_i - \hat{y}_i)^2, \tag{3.9}$$

onde y_i e $\hat{y}_i$ são as componentes do vetor formado por todos os valores de D_b e $\hat{D}_b$, respectivamente, e $\bar{y}$ é o valor médio das componentes y_i.

A equação que descreve o valor de R^2 a partir de SS_{tot} e SS_{res} é

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}, \tag{3.10}$$

de forma que, quanto menor o resíduo, mais próximo R^2 se encontra de 1.

3.3.2 Erro Relativo

O erro relativo é uma das formas mais diretas de avaliar o quanto, proporcionalmente, o valor medido ou predito aproxima-se do valor real. Ele é descrito como

$$\text{Erro Relativo} = \frac{\hat{D}_b - D_b}{D_b} = \frac{\Delta D_b}{D_b}, \tag{3.11}$$

onde D_b é o valor real e $\hat{D}_b$ é o valor predito. A fim de realizar a análise de como esse erro evolui ao longo do espectro de potências, neste trabalho foram considerados os valores máximos, mínimos e médios desse erro para cada valor de ℓ.

Capítulo

4

Resultados e Discussão

4.1 Validação e Escolha da Equação Final

Em um primeiro momento, foi realizada a validação dos dados, comparando principalmente a influência nos resultados de diferentes formas de tratamento dos dados de saída. A performance dos modelos para cada conjunto de tratamentos analisado, avaliada através do MSE, encontra-se descrita na tabela 4.1.

Tratamentos Utilizados	MSE_{max} (validação)	MSE_{min} (validação)
Normalização	$3,914 \cdot 10^{-2}$	$8,158 \cdot 10^{-5}$
Standardização	$1,000$	$5,297 \cdot 10^{-3}$
Escala logarítmica e Standardização	$9,999 \cdot 10^{-1}$	$2,105 \cdot 10^{-2}$
Escala logarítmica e Normalização	$1,909 \cdot 10^{-1}$	$1,625 \cdot 10^{-1}$

Tabela 4.1: Resultados durante a etapa de validação para os diferentes conjuntos de tratamentos dos dados de saída.

Ao fim dessa etapa, foi escolhido o modelo baseado apenas na normalização dos dados, que além de atingir o menor valor absoluto para o MSE, também manteve um bom grau de concordância entre os resultados de treino e validação, conforme pode ser visto na figura 4.1. Isto é um indício de que ele também foi relativamente eficaz em evitar o *overfitting* dos dados.

Uma vez escolhido o modelo sob o qual a regressão foi executada, foi necessário realizar a escolha da equação final. Esta escolha baseou-se no método "*Best*" do PySR, descrito na seção 3.2.2. A figura 4.2 apresenta a *loss* e o *score*, duas variáveis que determinam qual será a equação escolhida, em função da complexidade das equações. As linhas pretas contínuas na figura delimitam as equações cujo o *score* foi considerado para a escolha. Além disso, a figura também apresenta a equação escolhida e sua complexidade.

Dessa forma, a equação final é

$$D_\ell^{TT}(A_s, \tau, \Omega_m, \Omega_b, h, \ell) = 10^9 A_s \frac{a_0 P_1(\ell, \tau) P_2(\ell, \Omega_b, h)}{P_3(\ell, \Omega_m, h)} - a_1, \tag{4.1}$$

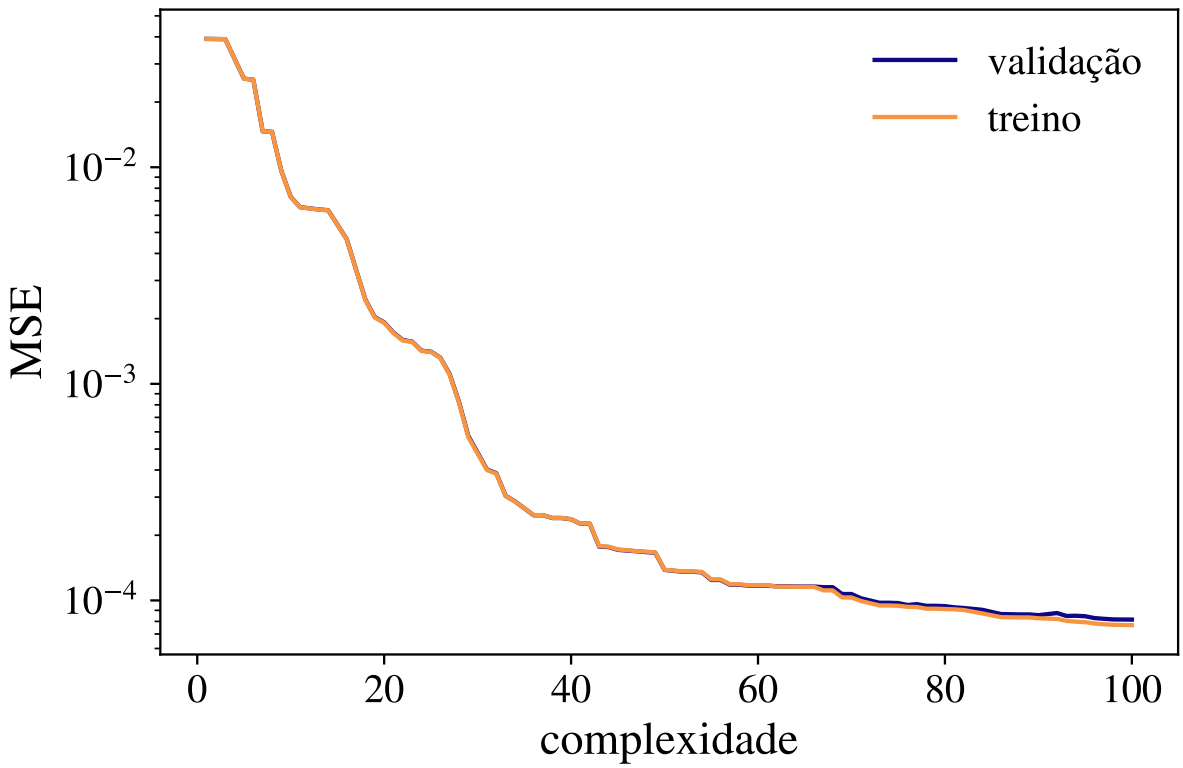

Figura 4.1: MSE das etapas de treino e validação em função da complexidade das equações fornecidas ao fim da regressão simbólica.

onde

$$P_1(\ell,\tau) = \sin\left(\sin\left(\frac{a_2}{e^{\sin(a_3\ln(\ell+a_4))}}\right) + \frac{a_5}{e^{a_6\ell}}\right) - a_7\tau, \tag{4.2}$$

$$P_2(\ell,\Omega_b,h) = \Omega_b h^2 - a_8\ell\sin(\ln(\ell)\sin(a_9\ln(\ell)+a_{10})) + a_{11}, \tag{4.3}$$

$$P_3(\ell,\Omega_m,h) = e^{\sin\left(a_{12}\ln(\ell)+a_{13}\sin\left(a_{14}\ell-\sin\left((\Omega_m+a_{15})\ln\left(\Omega_m h^2\right)\right)\right)\right)}, \tag{4.4}$$

e as constantes a_n que aparecem nas equações 4.1 a 4.4 encontram-se na tabela 4.2.

Analisando a forma geral desta equação, verifica-se que o termo $10^9 A_s$ aparece apenas como uma constante multiplicativa, conforme o esperado a partir da teoria cosmológica – vide as seções 2.1.6 e 2.1.7. Entretanto, o parâmetro n_s não aparece na equação, o que é indício de que seu efeito não tenha sido detectado ou que tenha sido mascarado por outro fator.

Quanto ao comportamento dos termos na forma P_i em função de ℓ, a partir da imagem 4.3, que faz a representação gráfica desses termos, vê-se que a contribuição de P_2 mantém-se aproximadamente constante em todo o espectro, com a presença de variações tênues, enquanto a combinação de P_1 e P_3 captura boa parte da variação do espectro, com $1/P_3$ sendo responsável pela estrutura dos picos, enquanto P_1 ajusta suas alturas.

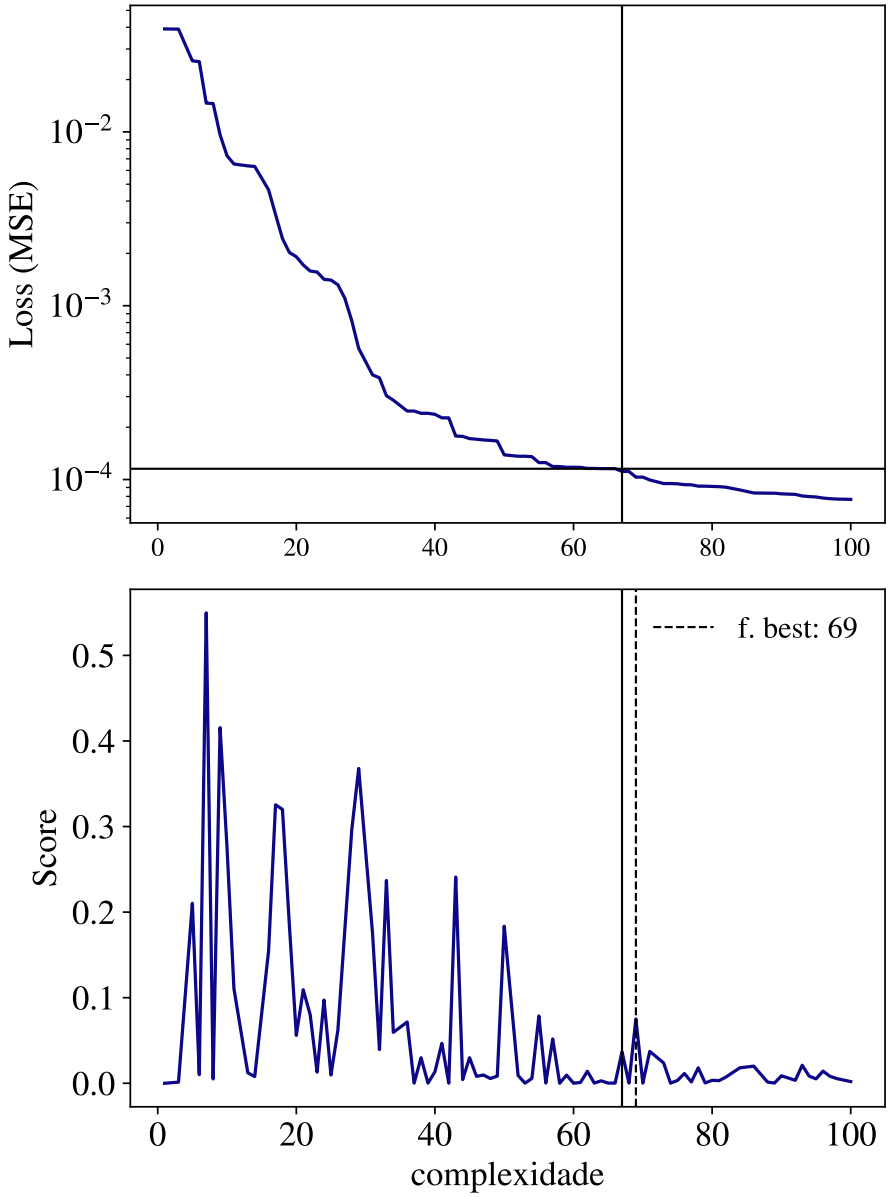

Figura 4.2: *Loss* (MSE) e *Score* das equações obtidas a partir do treino em função da complexidade. A linha horizontal contínua no primeiro gráfico apresenta o valor máximo de *loss* considerado de acordo com o método de seleção *best*. A linha vertical contínua em ambos os gráficos apresenta a complexidade correspondente a esse valor, ou seja, ela representa a complexidade a partir da qual foram avaliados os *scores* para a seleção da equação. A linha pontilhada representa a equação escolhida – a com maior *score* dentre as consideradas – para as análises detalhadas a seguir.

4.2 Avaliação de Performance

Com a equação final em mãos, torna-se possível realizar a etapa de teste do modelo. A figura 4.4 compara os valores preditos com os obtidos por meio do uso do CLASS para variações de parâmetros dentro dos intervalos de $\pm 1\sigma$ e $\pm 2\sigma$. No gráfico na parte superior da imagem, apresenta-se também os coeficientes de determinação para cada intervalo, cujos valores foram de $0,99881$ e $0,99863$ para os intervalos de $\pm 1\sigma$ e $\pm 2\sigma$ respectivamente. O gráfico da parte inferior dessa figura permite perceber que as variações entre os dados ficam abaixo de 10% para

a_n	valor
a_0	$(D_{max} - D_{min}) = 6599,54$
a_1	$0,0270190\,(D_{max} - D_{min}) - D_{min} = 120,222$
a_2	$0,942387$
a_3	$1,79876$
a_4	$23,6570$
a_5	$1,93933$
a_6	$0,249214$
a_7	$1,08623$
a_8	$1,72332 \cdot 10^{-5}$
a_9	$1,79592$
a_{10}	$0,300355$
a_{11}	$0,178601$
a_{12}	$0,941836$
a_{13}	$0,226981$
a_{14}	$0,0206624$
a_{15}	$4,54839$

Tabela 4.2: Valores das constantes listadas nas equações 4.1 a 4.4.

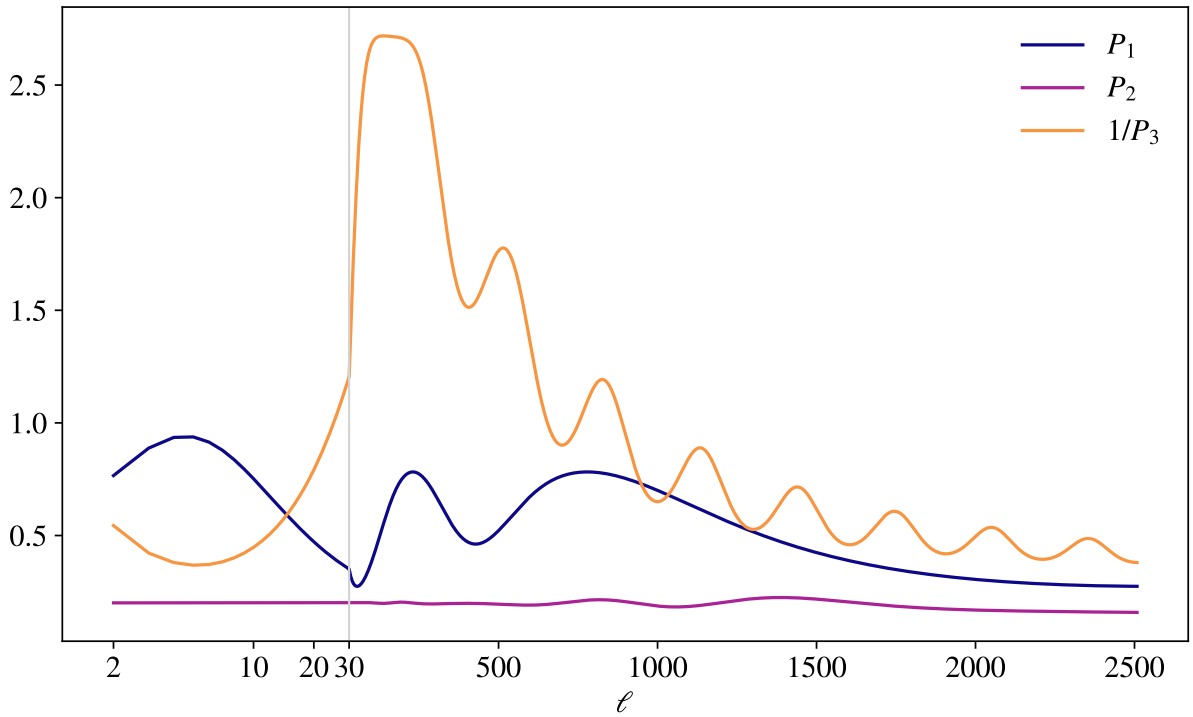

Figura 4.3: Funções P_1, P_2 e $1/P_3$ plotadas para o modelo cosmológico padrão.

$\ell \sim 1000$, embora haja uma forte discrepância para os valores de D_b menores que 500.

Estes valores correspondem aos monopolos mais altos ($\ell \sim 1500$), o que fica ainda mais claro ao se analisar os desvios em função do monopolo. Na figura 4.5, são plotados os desvios máximos, mínimos e médios dos dados de teste para $\pm 1\sigma$ e $\pm 2\sigma$. Neste gráfico, verifica-se que os desvios para monopolos menores que 1500 mantêm-se dentro de um intervalo de 10%, e

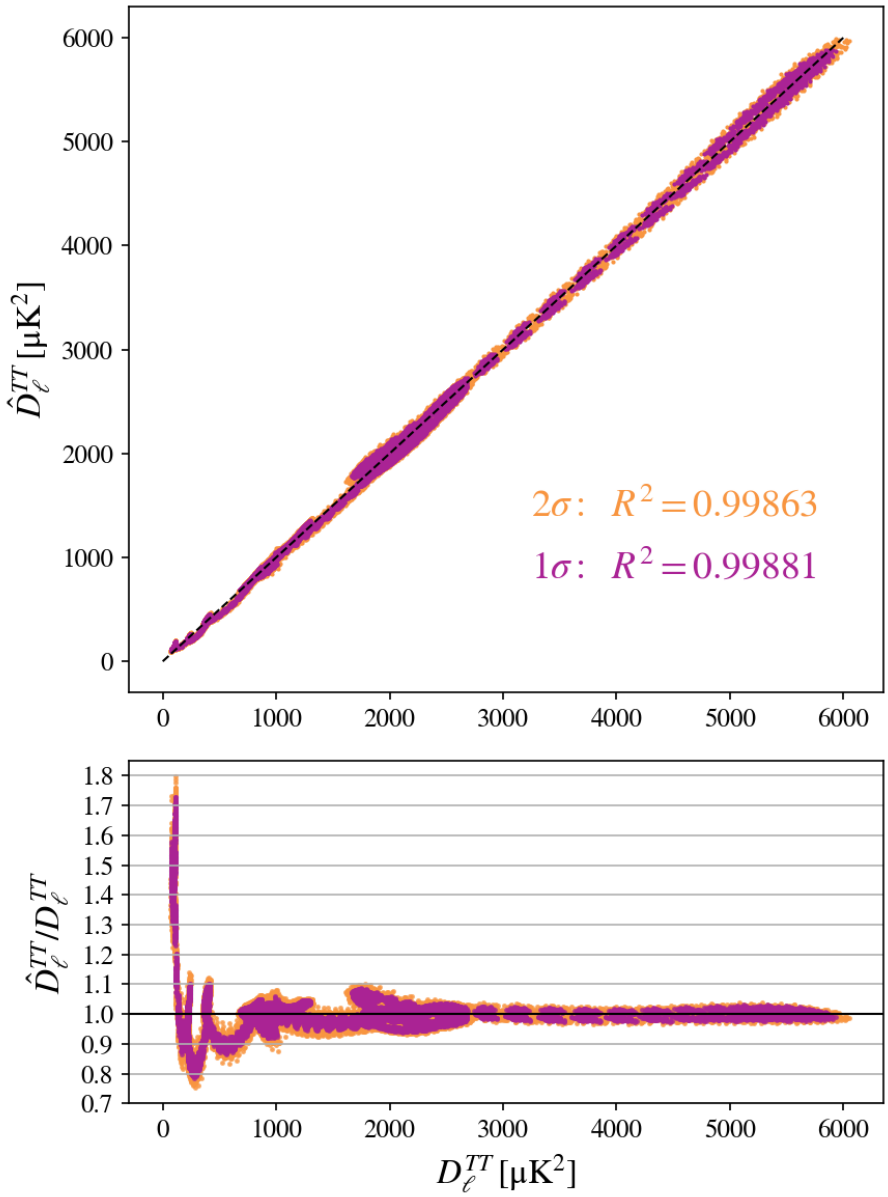

Figura 4.4: Comparação entre os D_b obtidos a partir dos dados computados pelo CLASS e os $\hat{D}_b$ preditos por meio da equação 4.1, obtida a partir da regressão simbólica para variações de parâmetros dentro do intervalo de $\pm 5\sigma$. No gráfico superior, além da distribuição desses valores, apresentam-se as medidas de R^2 para variações dos parâmetros dentro dos intervalos de $\pm 1\sigma$ e $\pm 2\sigma$. No gráfico inferior, encontra-se a razão entre o valor predito e o valor computado pelo CLASS para cada dado utilizado no teste.

começam a variar mais fortemente para $\ell \geq 1500$, atingindo os 80% de erro no final do espectro.

Ao se representar graficamente o espectro de potências para o modelo cosmológico padrão a partir dos parâmetros cosmológicos definidos pela colaboração Planck, é possível se ter indícios da razão deste erro: comparando o espectro gerado pela equação 4.1 (em azul) com o obtido a partir do CLASS (em laranja), observa-se que a principal dificuldade de adaptação do modelo treinado encontra-se no ajuste aos picos da CMB, ressaltando-se a exacerbação do último pico.

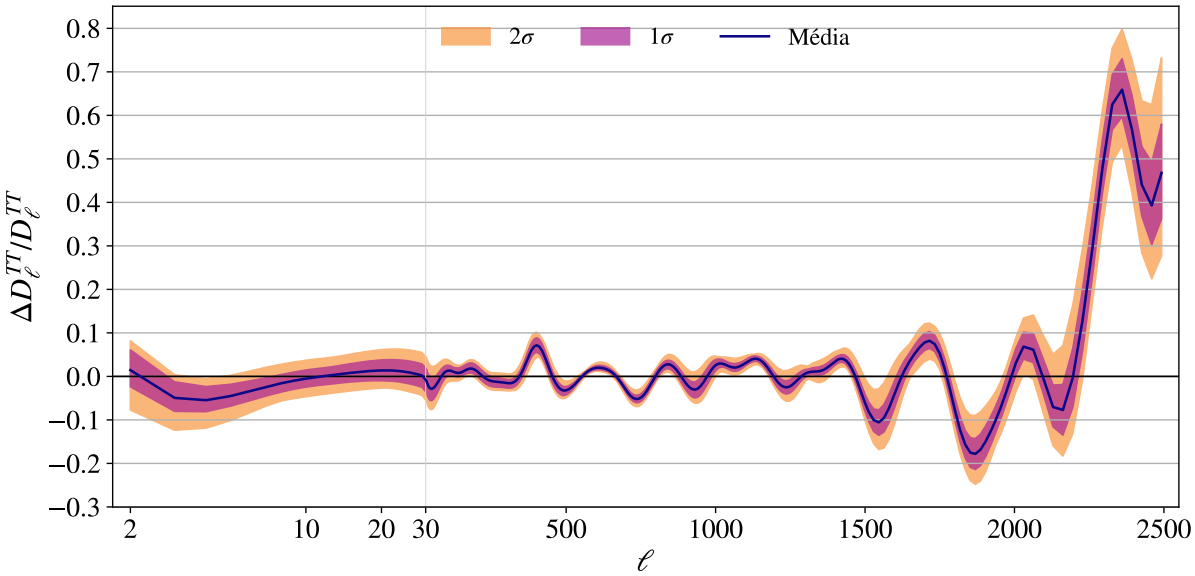

Figura 4.5: Desvios máximos e mínimos dos valores de $\hat{D}_b$ para variações de parâmetros dentro dos intervalos de $\pm 1\sigma$ e $\pm 2\sigma$.

Assim, verifica-se que, apesar do valor encontrado para o coeficiente de determinação, ainda fazem-se necessárias modificações para que este método possa atingir os níveis de acurácia encontrados pelos códigos de Boltzmann.

Possíveis melhorias a serem aplicadas envolvem:

- a combinação deste com outros métodos de aprendizado de máquina, a exemplo da combinação de regressão simbólica com *Neural Networks* sugerida por Cranmer *et al.* (2020) [39];
- a modificação das *targets*, passando a utilizar os termos apresentados por Mukhanov (2004) [28] durante a derivação analítica do espectro de potência;
- a modificação de hiperparâmetros como o número de iterações, as operações definidas ou o tamanho máximo da equação, a fim de aumentar o espaço de busca das equações;
- mudanças no número de amostras utilizadas no treino ou aumento do intervalo de variação de parâmetros, de forma que o algoritmo consiga perceber mais facilmente a influência de parâmetros como n_s.

Com a aplicação dessas melhorias, espera-se conseguir emular o espectro de potências da CMB com um nível de acurácia comparável ao obtido por Bartlett *et al.* (2024) [40] para o espectro de potências da matéria no regime linear.

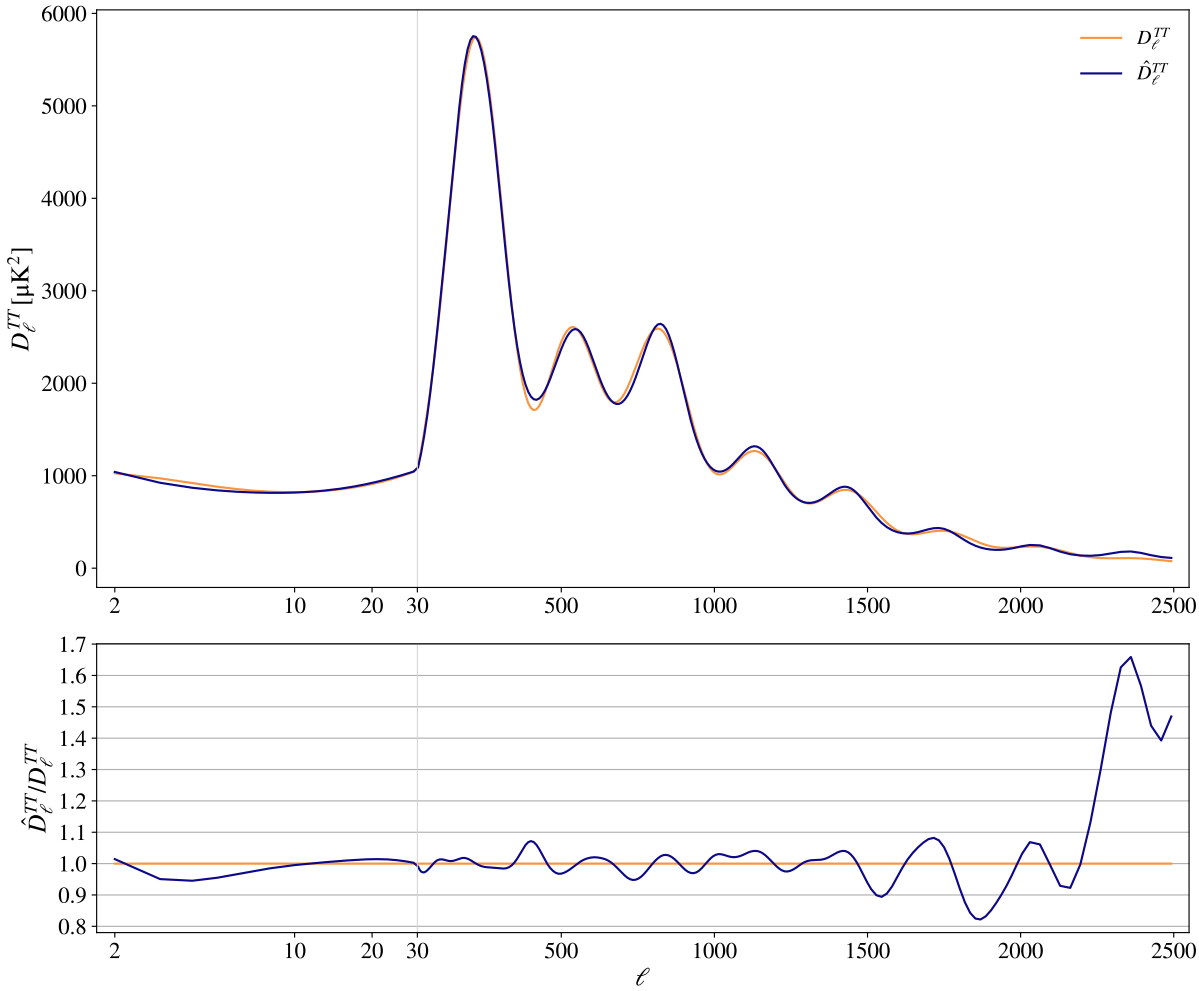

Figura 4.6: Espectros de potência obtidos para os parâmetros estimados pela colaboração Planck (2020a) [4] computados com o uso do CLASS (em laranja) e do modelo treinado com regressão simbólica (em azul). Na parte inferior da figura é apresentada a razão entre os valores preditos e os valores computados pelo CLASS.

Capítulo

5

Conclusões

"Se conhecemos um objeto apenas qualitativamente, nós o conhecemos apenas de maneira vaga. Se o conhecemos quantitativamente – entendendo alguma medida numérica que o distingue de um número infinito de outras possibilidades –, começamos a conhecê-lo profundamente. Percebemos parte da sua beleza e temos acesso ao seu poder e à compreensão que ele propicia"

(***Carl Sagan***)

Dado que o principal objetivo deste trabalho reside na obtenção de uma equação descritiva do espectro de potências da CMB a partir de um conjunto de parâmetros cosmológicos, para que esta equação forneça resultados comparáveis aos obtidos com o uso de códigos de Boltzmann, é necessário primariamente a delimitação do método mais eficaz em minimizar as informações perdidas ao se optar pelo modelo obtido com regressão simbólica.

Dentre as escolhas constituintes deste método, destacam-se o uso do *Latin Hypercube*, que permitiu que a distribuição dos parâmetros permanecesse uniforme mesmo com o baixo número de espectros; e a binagem dos dados, que permitiu a redução do número total de dados utilizados sem perda de informação dos espectros, conduzindo à redução do tempo computacional.

A partir do processo de validação do algoritmo, foi possível compreender o quão bem os diferentes processos de tratamento desempenharam a tarefa de apreender as relações entre os dados de entrada e saída, tendo o processo de normalização apresentado os melhores resultados. As perdas associadas às equações obtidas durante a validação por meio desse método encontram-se na faixa de $3,914 \cdot 10^{-2}$ a $8,158 \cdot 10^{-5}$. Além disso, dada a concordância entre os valores do MSE para os dados de treino e validação, este método obteve sucesso em evitar o *overfitting* dos dados.

A análise qualitativa dos termos contribuintes para a forma da equação, permitiu delinear como eles influenciam em diferentes regiões do espectro: verificou-se que $10^9 A_s$ dá a amplitude geral – conforme esperado –, enquanto os termos P_1 e $1/P_3$ dão a forma para os picos e P_2 atua adicionando algumas variações tênues ao longo do espectro. Entretanto, destaca-se o não aparecimento do parâmetro n_s, apontando para a não-detecção da influência desse parâmetro pelo algoritmo.

A partir da avaliação da equação obtida, foram encontrados coeficientes de determinação de $R^2 = 0,99881$ e $R^2 = 0,99863$ para variações dos parâmetros de entrada nas faixas de $\pm 1\sigma$ e $\pm 2\sigma$ dos valores obtidos pela colaboração Planck (2020a), respectivamente. Os desvios mínimos e máximos foram de aproximadamente 10% para $\ell < 1500$, aumentando para cerca de 25% para $1500 \leq \ell \leq 2200$ e atingindo 80% nos multipolos finais. Esse resultado aponta para a dificuldade do modelo em capturar a amplitude da variabilidade dos picos do espectro.

A fim de se melhorar os resultados obtidos fazem-se necessárias modificações ao modelo. Como perspectivas de refinamento para o método implementado, encontram-se: a mudança das *targets*, passando a utilizar os termos apresentados por Mukhanov (2004) [28] durante a derivação analítica do espectro de potência; a alteração de hiperparâmetros, a exemplo do número de iterações, as operações definidas ou o tamanho máximo da equação; realização de mudanças no conjunto de dados, por exemplo, aumentando o intervalo em que o parâmetro n_s varia ou aumentando o número de amostras; e a combinação deste com outros métodos de aprendizado de máquina.

Com a implementação de tais melhorias, espera-se que o modelo gerado seja capaz de emular o comportamento do espectro de potências da CMB, tal como proposto por Bartlett *et al.* (2024) [40] para o espectro de potências da matéria no regime linear.

Por fim, faz-se necessário ressaltar o potencial que a regressão simbólica possui para extrair relações físicas entre variáveis a partir do conjunto de dados. Isso a torna uma ferramenta de aprendizado de máquina cuja aplicação vem ganhando força em diversas áreas, dentre elas, a Astrofísica e a Cosmologia.

Referências

[1] Daniel Baumann. *Cosmology*. Cambridge University Press, Cambridge, United Kingdom New York, NY, 2022.

[2] D. J. Fixsen. The Temperature of the Cosmic Microwave Background. *The Astrophysical Journal*, 707(2):916–920, December 2009. arXiv:0911.1955 [astro-ph].

[3] Matthew Colless, Bruce A. Peterson, Carole Jackson, John A. Peacock, Shaun Cole, Peder Norberg, Ivan K. Baldry, Carlton M. Baugh, Joss Bland-Hawthorn, Terry Bridges, Russell Cannon, Chris Collins, Warrick Couch, Nicholas Cross, Gavin Dalton, Roberto De Propris, Simon P. Driver, George Efstathiou, Richard S. Ellis, Carlos S. Frenk, Karl Glazebrook, Ofer Lahav, Ian Lewis, Stuart Lumsden, Steve Maddox, Darren Madgwick, Will Sutherland, and Keith Taylor. The 2dF Galaxy Redshift Survey: Final Data Release, June 2003. arXiv:astro-ph/0306581.

[4] Planck Collaboration, N. Aghanim, Y. Akrami, M. Ashdown, J. Aumont, C. Baccigalupi, M. Ballardini, A. J. Banday, R. B. Barreiro, N. Bartolo, S. Basak, R. Battye, K. Benabed, J.-P. Bernard, M. Bersanelli, P. Bielewicz, J. J. Bock, J. R. Bond, J. Borrill, F. R. Bouchet, F. Boulanger, M. Bucher, C. Burigana, R. C. Butler, E. Calabrese, J.-F. Cardoso, J. Carron, A. Challinor, H. C. Chiang, J. Chluba, L. P. L. Colombo, C. Combet, D. Contreras, B. P. Crill, F. Cuttaia, P. de Bernardis, G. de Zotti, J. Delabrouille, J.-M. Delouis, E. Di Valentino, J. M. Diego, O. Doré, M. Douspis, A. Ducout, X. Dupac, S. Dusini, G. Efstathiou, F. Elsner, T. A. Enßlin, H. K. Eriksen, Y. Fantaye, M. Farhang, J. Fergusson, R. Fernandez-Cobos, F. Finelli, F. Forastieri, M. Frailis, A. A. Fraisse, E. Franceschi, A. Frolov, S. Galeotta, S. Galli, K. Ganga, R. T. Génova-Santos, M. Gerbino, T. Ghosh, J. González-Nuevo, K. M. Górski, S. Gratton, A. Gruppuso, J. E. Gudmundsson, J. Hamann, W. Handley, F. K. Hansen, D. Herranz, S. R. Hildebrandt, E. Hivon, Z. Huang, A. H. Jaffe, W. C. Jones, A. Karakci, E. Keihänen, R. Keskitalo, K. Kiiveri, J. Kim, T. S. Kisner, L. Knox, N. Krachmalnicoff, M. Kunz, H. Kurki-Suonio, G. Lagache, J.-M. Lamarre, A. Lasenby, M. Lattanzi, C. R. Lawrence, M. Le Jeune, P. Lemos, J. Lesgourgues, F. Levrier, A. Lewis, M. Liguori, P. B. Lilje, M. Lilley, V. Lindholm, M. López-Caniego, P. M. Lubin, Y.-Z. Ma, J. F. Macías-Pérez, G. Maggio, D. Maino, N. Mandolesi, A. Mangilli, A. Marcos-Caballero, M. Maris, P. G. Martin, M. Martinelli, E. Martínez-González, S. Matarrese, N. Mauri, J. D. McEwen, P. R. Meinhold, A. Melchiorri, A. Mennella, M. Migliaccio, M. Millea, S. Mitra, M.-A. Miville-Deschênes, D. Molinari, L. Montier, G. Morgante, A. Moss, P. Natoli, H. U. Nørgaard-Nielsen, L. Pagano, D. Paoletti, B. Partridge, G. Patanchon, H. V. Peiris, F. Perrotta, V. Pettorino, F. Piacentini, L. Polastri, G. Polenta, J.-L. Puget, J. P. Rachen, M. Reinecke, M. Remazeilles, A. Renzi, G. Rocha, C. Rosset, G. Roudier, J. A. Rubiño-Martín, B. Ruiz-Granados, L. Salvati, M. Sandri, M. Savelai-

nen, D. Scott, E. P. S. Shellard, C. Sirignano, G. Sirri, L. D. Spencer, R. Sunyaev, A.-S. Suur-Uski, J. A. Tauber, D. Tavagnacco, M. Tenti, L. Toffolatti, M. Tomasi, T. Trombetti, L. Valenziano, J. Valiviita, B. Van Tent, L. Vibert, P. Vielva, F. Villa, N. Vittorio, B. D. Wandelt, I. K. Wehus, M. White, S. D. M. White, A. Zacchei, and A. Zonca. Planck 2018 results. VI. Cosmological parameters. *Astronomy & Astrophysics*, 641:A6, September 2020. arXiv:1807.06209 [astro-ph].

[5] Deaglan J. Bartlett, Harry Desmond, and Pedro G. Ferreira. Exhaustive Symbolic Regression, May 2023. arXiv:2211.11461.

[6] Miles Cranmer. Interpretable Machine Learning for Science with PySR and SymbolicRegression.jl, May 2023. arXiv:2305.01582.

[7] Planck Collaboration, N. Aghanim, Y. Akrami, M. Ashdown, J. Aumont, C. Baccigalupi, M. Ballardini, A. J. Banday, R. B. Barreiro, N. Bartolo, S. Basak, K. Benabed, J.-P. Bernard, M. Bersanelli, P. Bielewicz, J. J. Bock, J. R. Bond, J. Borrill, F. R. Bouchet, F. Boulanger, M. Bucher, C. Burigana, R. C. Butler, E. Calabrese, J.-F. Cardoso, J. Carron, B. Casaponsa, A. Challinor, H. C. Chiang, L. P. L. Colombo, C. Combet, B. P. Crill, F. Cuttaia, P. de Bernardis, A. de Rosa, G. de Zotti, J. Delabrouille, J.-M. Delouis, E. Di Valentino, J. M. Diego, O. Doré, M. Douspis, A. Ducout, X. Dupac, S. Dusini, G. Efstathiou, F. Elsner, T. A. Enßlin, H. K. Eriksen, Y. Fantaye, R. Fernandez-Cobos, F. Finelli, M. Frailis, A. A. Fraisse, E. Franceschi, A. Frolov, S. Galeotta, S. Galli, K. Ganga, R. T. Génova-Santos, M. Gerbino, T. Ghosh, Y. Giraud-Héraud, J. González-Nuevo, K. M. Górski, S. Gratton, A. Gruppuso, J. E. Gudmundsson, J. Hamann, W. Handley, F. K. Hansen, D. Herranz, E. Hivon, Z. Huang, A. H. Jaffe, W. C. Jones, E. Keihänen, R. Keskitalo, K. Kiiveri, J. Kim, T. S. Kisner, N. Krachmalnicoff, M. Kunz, H. Kurki-Suonio, G. Lagache, J.-M. Lamarre, A. Lasenby, M. Lattanzi, C. R. Lawrence, M. Le Jeune, F. Levrier, A. Lewis, M. Liguori, P. B. Lilje, M. Lilley, V. Lindholm, M. López-Caniego, P. M. Lubin, Y.-Z. Ma, J. F. Macías-Pérez, G. Maggio, D. Maino, N. Mandolesi, A. Mangilli, A. Marcos-Caballero, M. Maris, P. G. Martin, E. Martínez-González, S. Matarrese, N. Mauri, J. D. McEwen, P. R. Meinhold, A. Melchiorri, A. Mennella, M. Migliaccio, M. Millea, M.-A. Miville-Deschênes, D. Molinari, A. Moneti, L. Montier, G. Morgante, A. Moss, P. Natoli, H. U. Nørgaard-Nielsen, L. Pagano, D. Paoletti, B. Partridge, G. Patanchon, H. V. Peiris, F. Perrotta, V. Pettorino, F. Piacentini, G. Polenta, J.-L. Puget, J. P. Rachen, M. Reinecke, M. Remazeilles, A. Renzi, G. Rocha, C. Rosset, G. Roudier, J. A. Rubiño-Martín, B. Ruiz-Granados, L. Salvati, M. Sandri, M. Savelainen, D. Scott, E. P. S. Shellard, C. Sirignano, G. Sirri, L. D. Spencer, R. Sunyaev, A.-S. Suur-Uski, J. A. Tauber, D. Tavagnacco, M. Tenti, L. Toffolatti, M. Tomasi, T. Trombetti, J. Valiviita, B. Van Tent, P. Vielva, F. Villa, N. Vittorio, B. D. Wandelt, I. K. Wehus, A. Zacchei, and A. Zonca. Planck 2018 results. V. CMB power spectra and likelihoods. *Astronomy & Astrophysics*, 641:A5, September 2020. arXiv:1907.12875 [astro-ph].

[8] A. A. Penzias and R. W. Wilson. A Measurement of Excess Antenna Temperature at 4080 Mc/s. *The Astrophysical Journal*, 142:419–421, July 1965. Publisher: IOP ADS Bibcode: 1965ApJ...142..419P.

[9] R. A. Alpher and R. C. Herman. Remarks on the Evolution of the Expanding Universe. *Physical Review*, 75(7):1089–1095, April 1949.

[10] D. J. Fixsen, E. S. Cheng, J. M. Gales, J. C. Mather, R. A. Shafer, and E. L. Wright. The

Cosmic Microwave Background Spectrum from the Full COBE/FIRAS Data Set. *The Astrophysical Journal*, 473(2):576–587, December 1996. arXiv:astro-ph/9605054.

[11] G. F. Smoot, C. L. Bennett, A. Kogut, E. L. Wright, J. Aymon, N. W. Boggess, E. S. Cheng, G. de Amici, S. Gulkis, M. G. Hauser, G. Hinshaw, P. D. Jackson, M. Janssen, E. Kaita, T. Kelsall, P. Keegstra, C. Lineweaver, K. Loewenstein, P. Lubin, J. Mather, S. S. Meyer, S. H. Moseley, T. Murdock, L. Rokke, R. F. Silverberg, L. Tenorio, R. Weiss, and D. T. Wilkinson. Structure in the COBE Differential Microwave Radiometer First-Year Maps. *The Astrophysical Journal*, 396:L1, September 1992. Publisher: IOP ADS Bibcode: 1992ApJ...396L...1S.

[12] S. Masi, P. A. R. Ade, J. J. Bock, J. R. Bond, J. Borrill, A. Boscaleri, K. Coble, C. R. Contaldi, B. P. Crill, P. de Bernardis, G. De Gasperis, G. De Troia, P. Farese, K. Ganga, M. Giacometti, E. Hivon, V. V. Hristov, A. Iacoangeli, A. H. Jaffe, W. C. Jones, A. E. Lange, L. Martinis, P. Mason, P. D. Mauskopf, A. Melchiorri, P. Natoli, T. Montroy, C. B. Netterfield, E. Pascale, F. Piacentini, D. Pogosyan, G. Polenta, F. Pongetti, S. Prunet, G. Romeo, J. E. Ruhl, F. Scaramuzzi, and N. Vittorio. The BOOMERanG experiment and the curvature of the Universe. *Progress in Particle and Nuclear Physics*, 48(1):243–261, January 2002. arXiv:astro-ph/0201137.

[13] Planck Collaboration, N. Aghanim, Y. Akrami, F. Arroja, M. Ashdown, J. Aumont, C. Baccigalupi, M. Ballardini, A. J. Banday, R. B. Barreiro, N. Bartolo, S. Basak, R. Battye, K. Benabed, J.-P. Bernard, M. Bersanelli, P. Bielewicz, J. J. Bock, J. R. Bond, J. Borrill, F. R. Bouchet, F. Boulanger, M. Bucher, C. Burigana, R. C. Butler, E. Calabrese, J.-F. Cardoso, J. Carron, B. Casaponsa, A. Challinor, H. C. Chiang, L. P. L. Colombo, C. Combet, D. Contreras, B. P. Crill, F. Cuttaia, P. De Bernardis, G. De Zotti, J. Delabrouille, J.-M. Delouis, F.-X. Désert, E. Di Valentino, C. Dickinson, J. M. Diego, S. Donzelli, O. Doré, M. Douspis, A. Ducout, X. Dupac, G. Efstathiou, F. Elsner, T. A. Enßlin, H. K. Eriksen, E. Falgarone, Y. Fantaye, J. Fergusson, R. Fernandez-Cobos, F. Finelli, F. Forastieri, M. Frailis, E. Franceschi, A. Frolov, S. Galeotta, S. Galli, K. Ganga, R. T. Génova-Santos, M. Gerbino, T. Ghosh, J. González-Nuevo, K. M. Górski, S. Gratton, A. Gruppuso, J. E. Gudmundsson, J. Hamann, W. Handley, F. K. Hansen, G. Helou, D. Herranz, S. R. Hildebrandt, E. Hivon, Z. Huang, A. H. Jaffe, W. C. Jones, A. Karakci, E. Keihänen, R. Keskitalo, K. Kiiveri, J. Kim, T. S. Kisner, L. Knox, N. Krachmalnicoff, M. Kunz, H. Kurki-Suonio, G. Lagache, J.-M. Lamarre, M. Langer, A. Lasenby, M. Lattanzi, C. R. Lawrence, M. Le Jeune, J. P. Leahy, J. Lesgourgues, F. Levrier, A. Lewis, M. Liguori, P. B. Lilje, M. Lilley, V. Lindholm, M. López-Caniego, P. M. Lubin, Y.-Z. Ma, J. F. Macías-Pérez, G. Maggio, D. Maino, N. Mandolesi, A. Mangilli, A. Marcos-Caballero, M. Maris, P. G. Martin, M. Martinelli, E. Martínez-González, S. Matarrese, N. Mauri, J. D. McEwen, P. D. Meerburg, P. R. Meinhold, A. Melchiorri, A. Mennella, M. Migliaccio, M. Millea, S. Mitra, M.-A. Miville-Deschênes, D. Molinari, A. Moneti, L. Montier, G. Morgante, A. Moss, S. Mottet, M. Münchmeyer, P. Natoli, H. U. Nørgaard-Nielsen, C. A. Oxborrow, L. Pagano, D. Paoletti, B. Partridge, G. Patanchon, T. J. Pearson, M. Peel, H. V. Peiris, F. Perrotta, V. Pettorino, F. Piacentini, L. Polastri, G. Polenta, J.-L. Puget, J. P. Rachen, M. Reinecke, M. Remazeilles, C. Renault, A. Renzi, G. Rocha, C. Rosset, G. Roudier, J. A. Rubiño-Martín, B. Ruiz-Granados, L. Salvati, M. Sandri, M. Savelainen, D. Scott, E. P. S. Shellard, M. Shiraishi, C. Sirignano, G. Sirri, L. D. Spencer, R. Sunyaev, A.-S. Suur-Uski, J. A. Tauber, D. Tavagnacco, M. Tenti, L. Terenzi, L. Toffolatti, M. Tomasi, T. Trombetti, J. Valiviita, B. Van Tent, L. Vibert, P. Vielva,

F. Villa, N. Vittorio, B. D. Wandelt, I. K. Wehus, M. White, S. D. M. White, A. Zacchei, and A. Zonca. *Planck* 2018 results: I. Overview and the cosmological legacy of *Planck*. *Astronomy & Astrophysics*, 641:A1, September 2020.

[14] V. M. Slipher. Spectrographic Observations of Nebulae. *Popular Astronomy*, 23:21–24, January 1915. ADS Bibcode: 1915PA.....23...21S.

[15] K. Lundmark. The determination of the curvature of space-time in de Sitter's world. *Monthly Notices of the Royal Astronomical Society*, 84:747–770, June 1924. Publisher: OUP ADS Bibcode: 1924MNRAS..84..747L.

[16] Edwin Hubble. A relation between distance and radial velocity among extra-galactic nebulae. *Proceedings of the National Academy of Sciences*, 15(3):168–173, March 1929. Publisher: Proceedings of the National Academy of Sciences.

[17] G. Lemaître. Un Univers homogène de masse constante et de rayon croissant rendant compte de la vitesse radiale des nébuleuses extra-galactiques. *Annales de la Société Scientifique de Bruxelles*, 47:49–59, January 1927. ADS Bibcode: 1927ASSB...47...49L.

[18] Francesco Sylos Labini and Yuri V Baryshev. Testing the Copernican and Cosmological Principles in the local universe with galaxy surveys. *Journal of Cosmology and Astroparticle Physics*, 2010(06):021–021, June 2010.

[19] A. Friedmann. On the Curvature of Space. *General Relativity and Gravitation*, 31(12):1991–2000, December 1999. Translation of the 1922 German original.

[20] A. Friedmann. On the Possibility of a World with Constant Negative Curvature of Space. *General Relativity and Gravitation*, 31(12):2001–2008, December 1999. Translation of the 1924 German original.

[21] H. P. Robertson. Kinematics and World-Structure. *The Astrophysical Journal*, 82:284, November 1935. Publisher: IOP ADS Bibcode: 1935ApJ....82..284R.

[22] A. G. Walker. On Milne's Theory of World-Structure*. *Proceedings of the London Mathematical Society*, s2-42(1):90–127, 1937.

[23] B. Ryden. *Introduction to cosmology*. Cambridge University Press, New York, NY, second edition edition, 2017.

[24] Stephen Blundell and Katherine M. Blundell. *Concepts in thermal physics*. Oxford University Press, Oxford New York, second edition, with corrections edition, 2017.

[25] George Arfken, Hans Weber, and Frank E. Harris. *Física Matemática: Métodos Matemáticos Para Engenharia E Física*. Elsevier, Rio de Janeiro, 2007. Tradução de: Mathematical methods for physicists, 6th ed.

[26] Scott Dodelson. *Modern cosmology*. Academic Press, San Diego, Calif, 2003.

[27] Andrew R. Liddle and David H. Lyth. *Cosmological inflation and large-scale structure*. Cambridge University Press, Cambridge, 2000.

[28] V. Mukhanov. CMB-slow, or How to Estimate Cosmological Parameters by Hand. *International Journal of Theoretical Physics*, 43(3):623–668, March 2004. arXiv:astro-ph/0303072.

[29] Edmund Bertschinger. COSMICS: Cosmological Initial Conditions and Microwave Anisotropy Codes, June 1995. arXiv:astro-ph/9506070.

[30] Uros Seljak and Matias Zaldarriaga. A Line of Sight Approach to Cosmic Microwave Background Anisotropies. *The Astrophysical Journal*, 469:437, October 1996. arXiv:astro-ph/9603033.

[31] Antony Lewis, Anthony Challinor, and Anthony Lasenby. Efficient Computation of CMB anisotropies in closed FRW models. *The Astrophysical Journal*, 538(2):473–476, August 2000. arXiv:astro-ph/9911177.

[32] Diego Blas, Julien Lesgourgues, and Thomas Tram. The Cosmic Linear Anisotropy Solving System (CLASS) II: Approximation schemes. *Journal of Cosmology and Astroparticle Physics*, 2011(07):034–034, July 2011. arXiv:1104.2933 [astro-ph].

[33] Aurélien Géron. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: concepts, tools, and techniques to build intelligent systems*. O'Reilly, Beijing Boston Farnham Sebastopol Tokyo, second edition edition, 2019.

[34] François Chollet. *Deep learning with Python*. Manning Publications, Shelter Island, second edition edition, 2021. OCLC: on1289290141.

[35] Viviana Acquaviva. *Machine learning for physics and astronomy*. Princeton University Press, Princeton Oxford, 2023.

[36] M. D. McKay, R. J. Beckman, and W. J. Conover. A Comparison of Three Methods for Selecting Values of Input Variables in the Analysis of Output from a Computer Code. *Technometrics*, 21(2):239, May 1979.

[37] Julien Lesgourgues. The Cosmic Linear Anisotropy Solving System (CLASS) III: Comparision with CAMB for LambdaCDM, May 2011. arXiv:1104.2934 [astro-ph].

[38] Thejs Brinckmann and Julien Lesgourgues. MontePython 3: boosted MCMC sampler and other features, April 2018. arXiv:1804.07261 [astro-ph].

[39] Miles Cranmer, Alvaro Sanchez-Gonzalez, Peter Battaglia, Rui Xu, Kyle Cranmer, David Spergel, and Shirley Ho. Discovering Symbolic Models from Deep Learning with Inductive Biases, November 2020. arXiv:2006.11287 [cs].

[40] Deaglan J. Bartlett, Lukas Kammerer, Gabriel Kronberger, Harry Desmond, Pedro G. Ferreira, Benjamin D. Wandelt, Bogdan Burlacu, David Alonso, and Matteo Zennaro. A precise symbolic emulator of the linear matter power spectrum, April 2024. arXiv:2311.15865 [astro-ph].

APÊNDICES

Apêndice

A

Configurações Utilizadas no CLASS

As configurações fixas fornecidas como *input* para a computação dos espectros encontram-se disponíveis na tabela A.1.

```
    'output': 'tCl',
    'lensing': 'no',
      'ic': 'ad',
     'modes': 's',
'l_max_scalars': 2508,
    'T_cmb': 2.7255,
     'Omega_k': 0.,
     'N_ur': 3.046,
      'YHe': 'BBN'
```

Tabela A.1: Parâmetros fixos usado para a computação dos C_ℓ^{TT} usados.

Os significados de cada parâmetro podem ser conferidos abaixo:

- a configuração `'output'` define o tipo de espectro que se deseja computar, o espectro de temperaturas da CMB (`'tCl'`);
- "`'lensing': no`" indica que não foram incluídas distorções referentes ao lenteamento dos fótons da CMB pela matéria em seu caminho;
- o parâmetro `'ic'` refere-se ao tipo de condições iniciais consideradas – neste caso, condições adiabáticas (`'ad'`);
- "`'modes': 's'`" indica que só devem ser consideradas do modo escalar;
- "`'l_max_scalars'`" fornece o máximo momento de multipolo ℓ a ser considerado ($\ell_{max} = 2508$);
- `'T_cmb'` e `'Omega_k'` definem os valores dos parâmetros cosmológicos $T_{\gamma,0}$ e Ω_k como $2,7255\,\mathrm{K}$ e 0, respectivamente;
- "`'N_ur': 3.046`" indica a densidade de espécies ultra-relativísticas de neutrinos não massivos;

- "'YHe'" indica a fração primordial de Hélio. Caso seja passado 'BBN', essa fração será inferida a partir da nucleossíntese do *Big Bang*.

Os parâmetros variados a cada computação e seus valores máximos e mínimos estão listados na tabela A.2. Salienta-se que o valor de 'h' é definido a partir dos parâmetros $\Omega_m h^2$ e Ω_m de cada entrada, por meio da relação

$$h = \sqrt{\frac{\Omega_m h^2}{\Omega_m}}. \tag{A.1}$$

Parâmetro Cosmológico	Parâmetro CLASS	Valor mínimo	Valor máximo
$\Omega_m h^2$	'omega_m'	$0,1375$	$0,1485$
$\Omega_b h^2$	'omega_b'	$0,02162$	$0,02312$
A_s	'A_s'	$1,95 \cdot 10^{-9}$	$2,25 \cdot 10^{-9}$
n_s	'n_s'	$0,9439$	$0,9859$
τ_{reio}	'tau_reio'	$0,0179$	$0,0909$
h	'h'	$0,6252$	$0,7298$

Tabela A.2: Parâmetros do CLASS variados para obtenção dos espectros e valores mínimos e máximos dentro dos quais os parâmetros poderiam variar.

Apêndice

B

Configurações Utilizadas na Regressão Simbólica

As configurações finais utilizadas para o treino dos dados encontram-se apresentadas na tabela B.1:

```
unary_operators=["log", "exp", "sin"],
binary_operators=["+", "*","^"],
constraints={‘mult’: (3, 3), "^": (1, 0), "exp": 1,
‘complexity_constants’:0, ‘sin’:5},
nested_constraints={"sin": {"sin": 2}, "log": {"log": 2},
"exp": {"exp":2}},
niterations=5000,
ncycles_per_iteration=200,
timeout_in_seconds= 60 * 60 * 240,
precision=32,
populations = 120,
maxsize = 100,
model_selection="best",
verbosity=3,
batching=True,
batch_size=16,
bumper=True,
turbo=True,
optimizer_iterations=10,
annealing=True,
optimize_probability=1.0,
weight_optimize=0.001,
parsimony=0.000000000001,
adaptive_parsimony_scaling=1000
```

Tabela B.1: Configurações fornecidas durante o treino dos dados.